QUICKCUT

项目指导手册

从多素材粗筛，到可继续精修的视频工程

共同目标	故事明确、素材有据、音画一致、工程可编辑
协作方式	六个模块独立开发，以统一输入输出贯通
技术原则	本地推理；复用现有 MVP；由粗粒度逐步细化

团队设计稿 v0.1 | 2026-11-06

本 PDF 合订总指南、技术基线、六人任务书、接口契约与样例使用说明。图表可直接阅读；源码、完整 JSON 样例和校验器保留可点击仓库链接。

状态区分：已实现 / 已验证样例 / 目标设计 / 待验证。多素材自动编排及剪映工程输出属于下一阶段目标。

仓库与可编辑源文档

目录

建议先读第一篇了解全局，再读第二篇确认现状；各负责人按第三篇领取任务，并以第四篇的协议进行交接。

第一篇 总体目标与由粗到细的工作流 4

读者导航 . . . 4
1. 我们共同交付的产品 . . . 4
2. 由粗到细：先确定值得讲的内容，再精确决定哪里切 . . . 5
3. 完整目标工作流，以及每条箭头意味着什么 . . . 7
4. 技术架构与最小选型 . . . 10
5. 六人职责与协作方式 . . . 12
6. 独立并行开工：先统一合同，再替换真实上下游 . . . 13
7. 验收：需要看到什么证据 . . . 15
8. 从现有代码迁移，而不是一次性重写 . . . 15
9. 开发、交接与复现约定 . . . 16
10. 需要记录的设计决策 . . . 17
11. 术语对照 . . . 18

第二篇 现有 MVP 基线与技术选型 19

1. 当前产品实际上能做什么 . . . 19
2. 两条现有处理路径必须区分 . . . 20
3. 真实技术选型与默认值 . . . 21
4. 逐句配音与原声处理的可复用能力 . . . 22
5. 文件到六人职责的映射 . . . 22
6. 新同事的最小启动顺序 . . . 23
7. 当前缓存、时间线和编辑中的迁移陷阱 . . . 24
8. 下一阶段的复用建议 . . . 25

目录（续）

第三篇 六人实施任务与交接 26

1. 我们共同交付的是什么 . . . 26
2. 六个模块与边界 . . . 26
3. A：素材接入与索引 . . . 27
4. B：检索与外部空镜库 . . . 28
5. C：故事与视听规划 . . . 29
6. D：精剪与时间线编排 . . . 30
7. E：本地配音与字幕 . . . 31
8. F：渲染与剪映交付 . . . 32
9. 第一轮共同准备：标准样例与接口冻结 . . . 34
10. 里程碑与汇合方式 . . . 34
11. 跨模块问题由谁处理 . . . 35
12. 每次交付的共同要求 . . . 35
13. 整体完成标准 . . . 36

第四篇 模块接口与交付契约 37

1. 我们用这些数据共同完成什么 . . . 37
2. 所有模块共享的基本约定 . . . 38
3. 八个对象的最小字段 . . . 40
4. 黄金样例如何贯通六人交接 . . . 42
5. 修改之后哪些东西失效 . . . 43
6. 有限反馈循环和失败结果 . . . 43
7. 从当前 MVP 渐进迁移 . . . 45
8. 协议修改与交接清单 . . . 45

附录 协议样例的使用与验证 46

检查样例 . . . 46
占位媒体与证据边界 . . . 46
每位同事如何使用 . . . 47

第一篇 总体目标与由粗到细的工作流

可编辑源文件：docs/PROJECT_GUIDE.zh-CN.md

版本：团队设计稿 v0.1 · 更新日期：2026-11-06（Asia/Taipei）

代码审计基线：6cb978d · 仓库：https://github.com/Tt200411/QuickCut

本文件面向全部六位参与者，也是需求、研发、测试和交接的共同入口。先读工作流，再读自己的任务书，最后按数据协议实现。团队成员可以直接引用文中的任务、表格、流程图和示例用于分工、Issue、PR 和讨论；这份说明不改变原仓库或第三方素材、模型的授权条款。

状态约定：“已实现”有当前代码支撑；“已验证样例”只指特定素材和配置；“目标设计”是接下来共同实现的能力；“待验证”需要实验或目标软件实机确认。下文的完整多素材工作流是目标设计，不是现有 MVP 已经全部具备的功能。

读者导航

你需要做什么	阅读入口
先理解我们在做什么、为什么这样分层	本文第 1-4 节
确认当前代码能做什么，避免重复开发	MVP 基线与复用地图
领取自己的实现任务、明确边界和交付	六人任务书
独立开发、对接上下游、处理版本与时间	模块协议与迁移设计
立即使用一套一致的模拟输入输出	黄金协议样例
复现已经审阅的中文视频样例	中文样例说明
复用和修改图	总体工作流、交付图、配音时序图

1. 我们共同交付的产品

用户可能上传一条十分钟视频，也可能上传二十个手机短片：出发、车窗、步行、朋友互动、吃饭和休息。用户首先给出成片要求，例如：“做一条一分钟内的中文 VLOG，从城市出发，到山里慢慢放松；开头紧凑，结尾安静，保留现场环境声。”

系统应围绕这个要求整理素材、判断哪些事件有画面支持、安排能交代环境或承接情绪的外部空镜，并把它们组成可理解的故事。配音与字幕同样围绕故事编排。用户最终拿到可以在剪映继续精修的工程：可以替换一个镜头、延长一个空镜、换一句配音、调低音乐，而不必重做全部内容。

交付核心是**可编辑工程和素材包**；预览 MP4、时间线 JSON、配音文件、字幕及检查报告作为配套产物。第一阶段把“模板”定义为可编辑草稿工程；“任意更换素材后自动复用的模板商品”需要额外的占位符和约束设计，不属于首轮验收。

1.1 已确认的产品要求

- 输入支持多个短视频、一个长视频，以及两者混合；保持每个片段到原文件的可追溯关系。
- 用户故事、类型、风格、时长在开始时输入，参与粗筛；粗筛后依据实际素材进行一次故事与素材的二次对齐。
- 外部空镜库参与环境建立、转场、情绪留白和结尾设计。具体人物和事件仍以用户素材证据为依据。
- 支持 VLOG 和微电影式叙事，允许旁白、内心独白和现场原声的不同组合。
- 视觉理解、ASR、文案生成与 TTS 在本地运行。“外部素材/配音”是相对于原始视频而言，不表示云端推理。
- 从素材级、事件级、镜头级逐步走向边界级；高成本视觉分析只用于值得保留的候选。
- 剪映工程中保留独立画面、原声、旁白、字幕和必要的音乐/音效轨。预览可以烧录字幕，工程里的字幕仍须可编辑。
- 第一轮端到端验收先沿用现有 5-60 秒预算；更长视频放在后续扩展，不靠重复镜头或空洞文案凑时长。

1.2 首轮范围与扩展范围

首轮必须闭环	后续扩展
多文件导入、可追溯候选、实际语义检索	大规模向量库、跨项目素材服务
主素材与空镜联合规划、三段基本故事结构	复杂非线性叙事、更多风格策略
本地旁白、逐句字幕、原声保留	多角色对白、声音克隆、口型同步
可编辑时间线、基础硬切、可调整音量	复杂转场、特效、自动作曲与高级调色
指定版本剪映实际打开、编辑、保存、再导出	多剪辑软件适配和通用模板系统

首轮应使用一个可工作的编排链路，而不是六个彼此独立的演示程序。系统主动标出缺少证据、配音超时和导出不支持的功能，比生成表面完整、实际无法继续编辑的结果更重要。

2. 由粗到细：先确定值得讲的内容，再精确决定哪里切

“粒度”描述我们正在处理的单位，“阶段”描述正在做的事情，两者需要区分。一个素材可能在粗筛时已经被淘汰，不必再做逐帧动作分析。

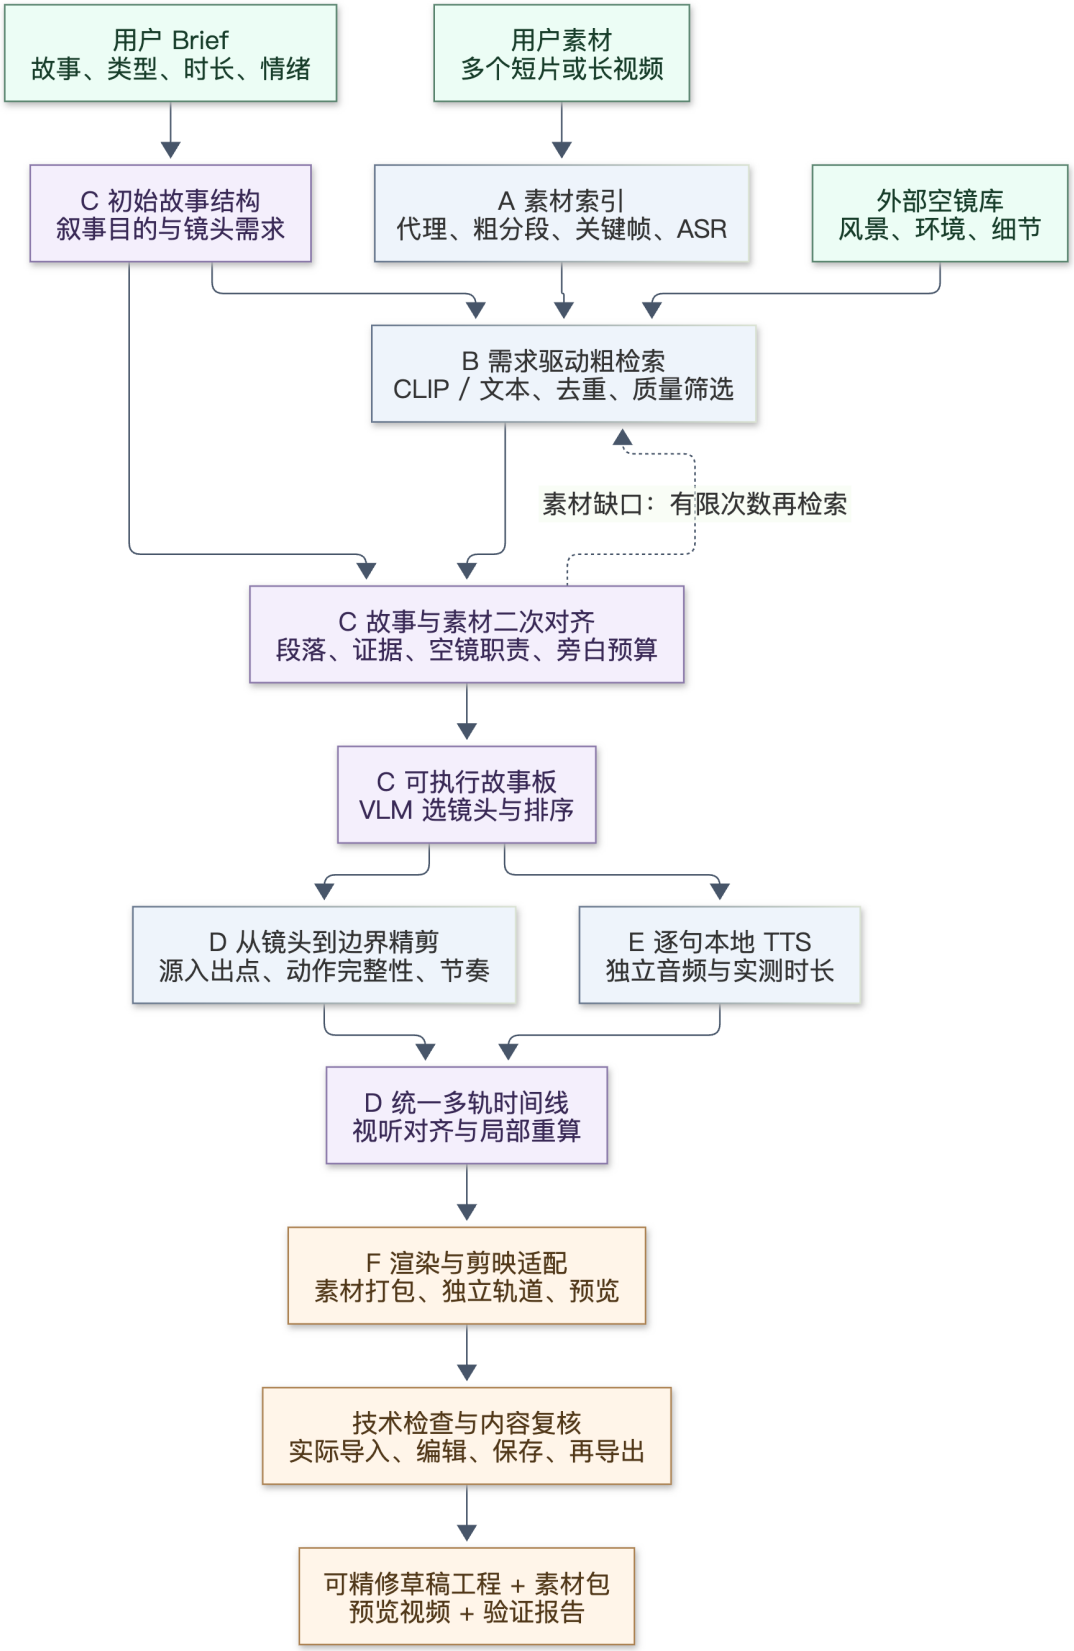
粒度	处理对象与目的	主要方法	输出与负责人
L0 素材级	完整文件；确认格式、可解码性、重复文件、横竖屏、时长与原声	FFmpeg/ffprobe、哈希、稀疏抽帧、代理生成	A 的资产目录与质量信息

粒度	处理对象与目的	主要方法	输出与负责人
L1 场景/事件级	一次活动、一个场景、一段完整讲话；确定故事素材范围	场景边界、ASR 段落、时间与视觉相似性、必要的 VLM 概括	A 的分段和 B 的候选分组，C 确认叙事用途
L2 镜头级	同一事件的多个视角；保留关键动作，去掉重复覆盖	CLIP/文本召回、质量排序、VLM 比较、故事约束	C 的故事板与镜头选择
L3 边界级	被选镜头附近的帧和音频；定位入点出点	局部密集采样、镜头切换、动作变化、语音停顿	D 的精剪区间

场景边界是画面的变化；事件边界是语义活动的变化，两者不必一致。长视频需要逐层拆分，短视频可先整体作为候选，必要时再拆。一个事件也可能由多个源文件共同表达，不能把文件顺序默认当作故事顺序；拍摄时间、地点等缺失时应显式保持未知。

现有 MVP 的“每 3 秒一个窗口、抽中点关键帧”可作为 L0/L1 的基线，不应直接宣称具备场景识别。下一阶段先引入可替换的分段器，再对入选区间增加多帧分析。采样密度、窗口长度、候选数量都是配置，应记录其效果和成本后再冻结。

3. 完整目标工作流，以及每条箭头意味着什么



QuickCut 由粗到细工作流 · 目标架构，具体接口与反馈规则见正文。

图的可编辑 Mermaid 源文件见 quickcut-coarse-to-fine.mmd。所有模块之间传递的是结构化数据和媒体文件引用，不是只靠一段自然语言约定。

阶段 1：需求与素材分别进入系统

C 把用户要求转成 Brief：故事意图、成片类型、时长预算、语言、画幅、节奏、旁白偏好、必须保留的事件。A 同时处理素材，生成 AssetManifest。用户信息和模型推测分开存储；例如“是同一个地点”不能仅因为两张图都是绿色就作为事实写入。

外部空镜库也必须有资产 ID、可定位文件、长度、画幅和来源记录。B 负责库的检索与语义标签，通用媒体探测与抽帧能力复用 A，避免两套素材规范。

阶段 2：初始故事驱动粗筛

C 先提出叙事段落及其需要表达的内容，再向 B 提交 RetrievalRequest。B 从用户素材召回能支撑事件的画面，从外部库召回能承担空镜职责的画面。候选保留相关性、质量和来源，不直接把最高分镜头排进成片。

例如“抵达山里”可能需要用户下车的主镜头，再接环境空镜。空镜可以表达氛围；未经证据支持，不把外部山景描述成用户确实抵达的具体山峰。

阶段 3：故事-素材二次对齐

C 将“用户想讲什么”“实际拍到了什么”“空镜库能补充什么”放在一起，调整段落、篇幅和镜头职责。这是第一轮故事可执行性检查：哪些事件有证据，哪些只能用旁白表达主观感受，哪些需要调整叙述，哪些需要继续检索。

这一阶段的输出是 StoryPlan，每段至少有叙事目的、证据片段、主镜头、空镜位置及职责、时间预算、旁白文本和未解决缺口。空镜安排是主动的结构设计，不只是发现素材不足后的补片。

段落示例	主素材用途	空镜用途	声音安排
出发	收拾背包、上车，建立人物行动	城市环境或车窗细节	简短旁白，保留关车门或街道声
探索	步行、交流、观察，推动事件	林间光影、溪流，连接不同视角	旁白与现场声音交替
放松	坐下休息、人物表情，完成情绪变化	稍长的环境画面，承接结尾	放缓语速，留出原声

再检索是有上限的循环。建议 P0 同一缺口最多检索三轮（首次检索加两次修订后的再检索），仍未满足则返回具体缺口给用户或人工编辑；该上限是待团队确认的策略值，不是现有代码行为。配音适配另按协议限制为同一句最多两轮。

阶段 4：VLM 镜头选择与 D 的精剪

C 把有限的真实候选关键帧、编号、源时间、ASR 证据和段落目标交给本地 VLM。它提出选镜头和排序。程序检查素材 ID、来源、重复、事件覆盖和时长，再由 D 细化入出点。

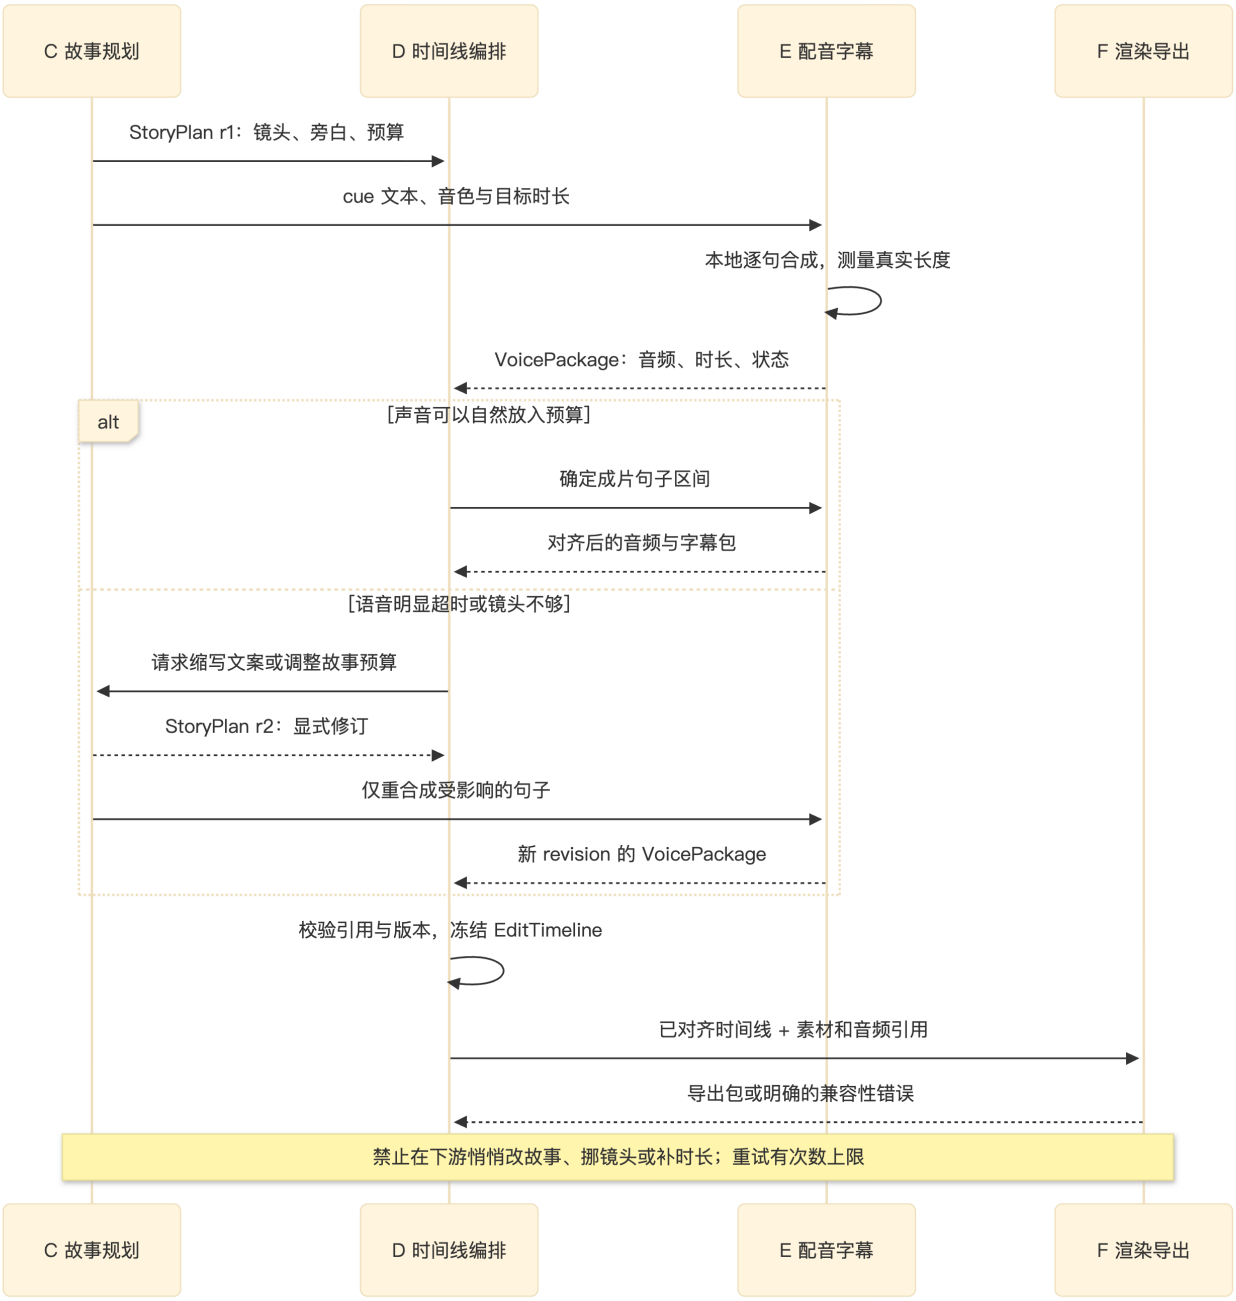
程序改变了模型顺序、人工锁定了必选镜头、或重写了旁白，都要记录来源与理由。模型能生成合法 JSON 只说明输出格式合法，不证明角色、动作和因果关系正确。关键事件要有画面对照验证。

D 可以裁掉准备动作或冗余等待，但需要保留让观众理解事件的最小上下文。切换两个视角时检查动作、方向和声音；遇到动作证据不足时保留较完整区间，不仅依据一张中点图片切断事件。

阶段 5：配音参与时间安排

C 负责说什么，E 负责声音如何生成以及真实长度，D 负责它在成片中的位置。旁白、内心独白、现场对白和纯环境声段落都应有明确标识。

E 按句生成独立音频，清理边界静音并测量时长。对于已经审阅的画面区间，配音应在自然语速范围内适配；明显超时则返回 needs_retime。D 可以调整镜头、空镜或段落预算，文案需要缩写则交回 C。字幕由实际播音文本及确定的时序生成，不使用 ASR 猜测结果作为最终字幕原文。



配音定时反馈 · 目标架构，具体接口与反馈规则见正文。

图中的 revision 表示实际内容版本。旧旁白包不能直接覆盖新故事板；修改一句话只重做这句话及受影响的字幕，避免无意义重跑整个视频。全局镜头时间只由 D 更新。

阶段 6：生成工程与预览

F 读取冻结版本的 EditTimeline、VoicePackage 和素材引用，输出预览 MP4 和剪映工程包。两者从同一份时间线生成，避免预览与工程出现不同镜头或不同配音时序。

工程保留独立轨道和媒体引用，预览允许烧录字幕。工程中只导入一个已经混音、烧字幕的 MP4 不满足验收。目标剪映版本、操作系统、工程放置/导入方式、素材重定位方式必须先由 F 实机确认。

阶段 7：技术与内容两类验收

技术检查覆盖解码、时间戳、时间区间、音轨存在性、原声保留、包内路径和剪映可编辑性。内容检查覆盖人物动作、因果顺序、空镜职责、旁白是否对得上当时画面、故事有没有结果。PTS=0 和“ASR识别到最后一秒”不能替代内容检查。

4. 技术架构与最小选型

第一阶段沿用 Python 主工程和现有本地模型，把业务能力拆成清楚的 Python 模块与可独立运行入口。FastAPI/Uvicorn 负责请求与任务状态，Gradio 负责轻量工作台；它们不是模型推理框架。先做单机模块化架构，不要求六位同事各搭一个网络服务。

媒体文件保存在本地项目目录，结构化记录先使用版本化 JSON。任务记录、缓存索引可按需要引入 SQLite；没有必要为首轮验证先部署向量数据库和复杂消息队列。Ollama、ASR 和渲染任务由 D 的编排器限制并发，避免多人同机调试同时耗尽内存。

模块	当前可复用基线	下一阶段最低技术方案	负责人 / 状态
探测、代理、抽帧	FFmpeg、imageio-ffmpeg；关键帧缓存	使用 ffprobe 完整采集媒体参数；增加多资产与代理时间映射	A / 多资产待实现
粗分段	固定 3 秒窗口	固定窗口保持基线；评估 PySceneDetect Content/Adaptive 场景边界，再结合 ASR 分段	A / 场景检测待验证
视觉检索	默认颜色直方图；可选 OpenCLIP adapter（MobileCLIP-S2 / datacompdr）	冻结可用权重；对中文查询做实测，必要时本地查询改写或评估多语言编码器	B / adapter已有，语义效果待验收
原声 ASR	faster-whisper tiny、CPU int8、VAD	保留本地缓存；需要更高准确率时比较 small，记录实测延迟	A / 已实现
视觉故事规划	Qwen2.5-VL 3B、Ollama、带编号接触表与 JSON 约束	分段/分幕调用、完整证据映射、显式校验与有限纠正	C / 基线已实现，通用多素材待实现
时间线	现有 Python dataclass、单一 source_video	多资产 IR、整数微秒、独立轨道、修订关系与局部失效	D / 升级待实现
本地 TTS	macOS say，中文 Reed、rate 145，逐句 WAV；espeak 兜底	先保留本机基线；跨平台或情绪能力由 E 用同文小样评估后另行冻结	E / 本地基线已实现
字幕与混音	SRT、FFmpeg/libass、PCM 中间音频、独立旁白	保留可编辑字幕和独立音频资产；混音参数进入时间线	E/F / 多轨契约待扩展
剪映导出	无	先最小工程实机验证，再实现版本化 exporter；无效或不支持时明确报错	F / 待验证与实现

选型依据：Qwen 的官方模型卡确认了所用 3B 视觉语言模型；Ollama 的本地生成接口支持图像输入和 JSON Schema 输出。我们沿用当前能运行的组合，不把更换最新模型作为多素材改造的前提。Qwen 官方模型卡 · Ollama Generate API

OpenCLIP 为图像和文本提供编码与相似度计算，具体中文检索能力需要项目样例验证；ASR 使用的 faster-whisper 基于 CTranslate2。PySceneDetect 的 Content/Adaptive 检测器是场景切分候选，不等同于完

整事件理解。OpenCLIP 官方仓库 · faster-whisper 官方仓库 · PySceneDetect 检测器文档

4.1 当前 MVP 与目标的差距

当前审阅过的中文样例由单个源视频选出 20 个窗口，形成 58.5 秒结果，使用 39 张候选关键帧、分幕 Qwen 调用及人工润色的 11 句中文旁白。索引的实际 encoder 是颜色直方图，不是 CLIP。样例中的三幕候选区间及部分必选事件也来自人工审阅。

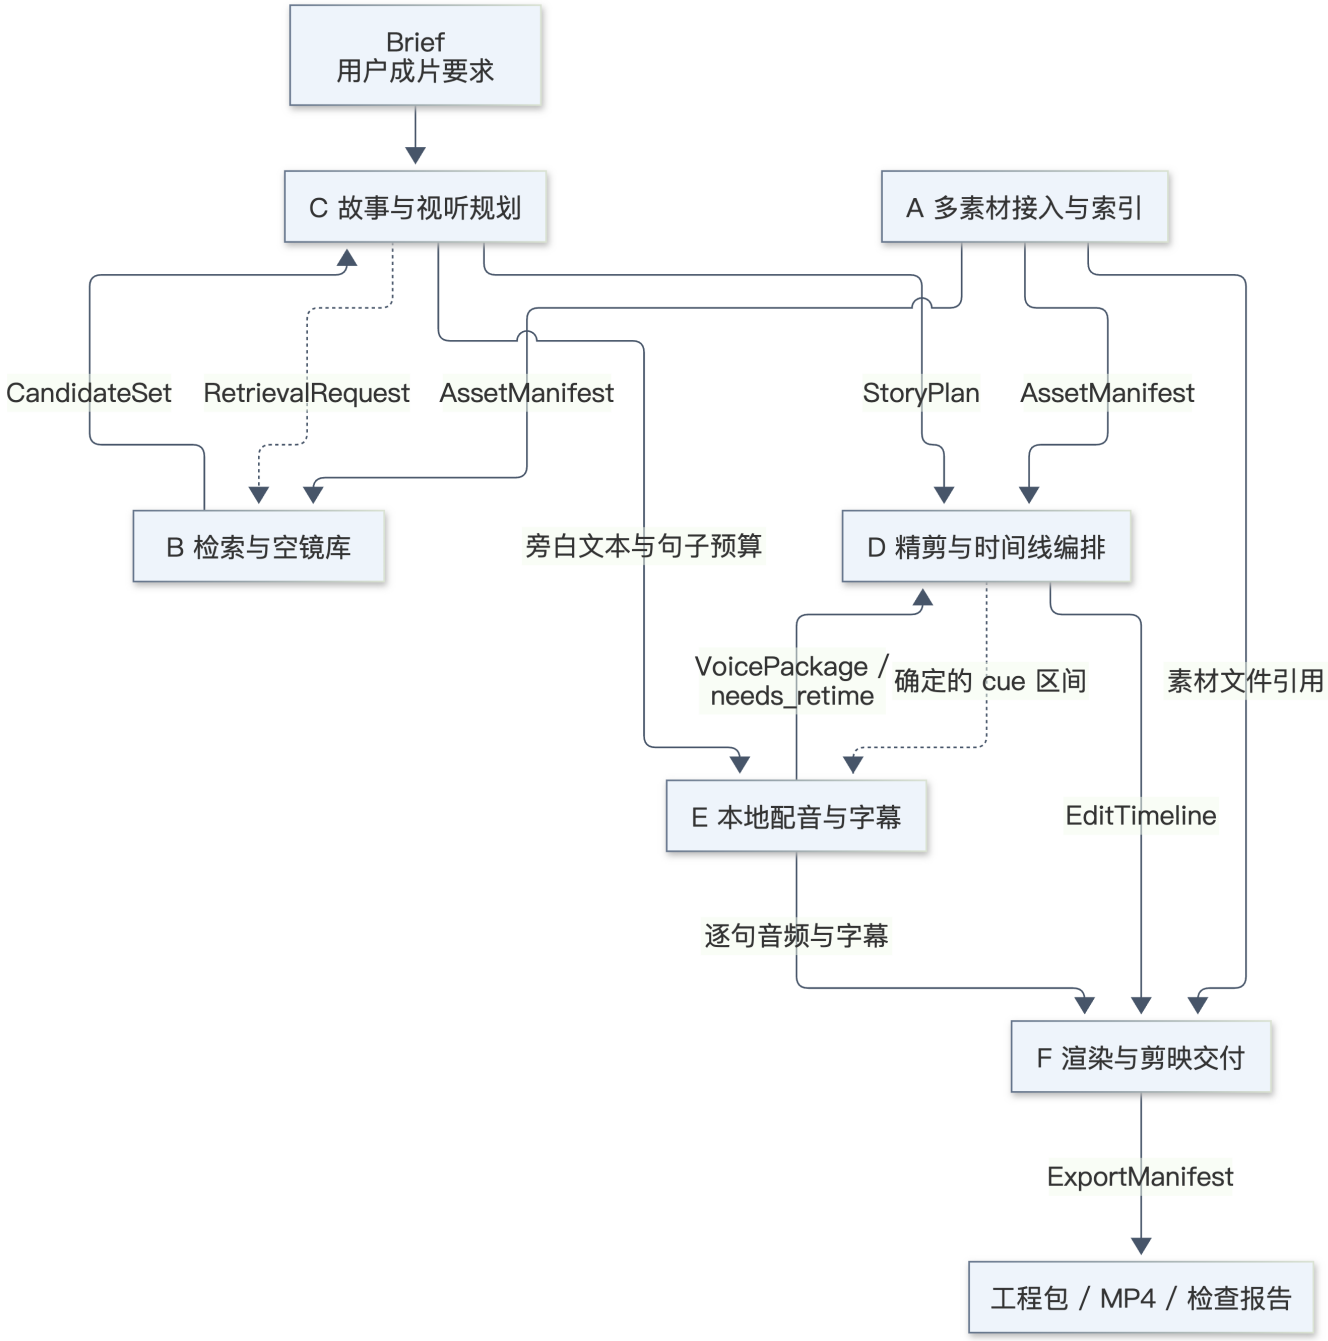
2026-11-06 对基线运行 .venv/bin/python -m pytest -q 得到 82 passed。这些测试证明现有功能的回归结果，不证明目标多素材流程或剪映导出已经完成。

必须优先补齐的工程缺口：

1. Timeline.source_video 是单文件字段，不能仅靠增加一个文件列表就支持跨素材裁切。
2. 当前 asset_id 在旧时间线中常实际表示 shot ID；新协议要拆清资产 ID 和片段 ID。
3. Gradio 的索引检索入口没有完整调用分幕 Qwen 规划；镜头编辑后也没有完整失效重算。
4. 通用 basic 路径和已审阅中文脚本的规划、校验、保存顺序不同，不能混为同一个已验证工作流。
5. 某些 CLI 路径先写时间线文件再生成 TTS，可能漏掉合成后更新的实际字幕时序；新流程必须在最终对齐后保存同一 revision 的交付记录。
6. 剪映工程格式、目标版本与可编辑性尚未验证，不能写成“已有通用导出标准”。

完整源码引用与命令见 MVP 基线。

5. 六人职责与协作方式



团队交付图 · 目标架构，具体接口与反馈规则见正文。

同事	一句话职责	交付什么	主要消费者
A	把原始文件变成真实、可定位的素材事实	AssetManifest、代理、关键帧、ASR、缓存	B、D、F
B	从用户素材和空镜库召回合适候选	CandidateSet、检索入口、候选解释	C
C	决定故事表达、镜头职责和旁白内容	StoryPlan、检索请求、模型推理记录	B、D、E

同事	一句话职责	交付什么	主要消费者
D	把故事编译成统一的成片时间安排	EditTimeline、编排入口、编辑与局部重算	E、F
E	生成本地声音并报告实际时长	VoicePackage、逐句音频、字幕与对齐状态	D、F
F	忠实执行时间线并交付可精修工程	ExportManifest、剪映包、预览、验证报告	用户、全组

每个人都写自己的模块测试；D 维护编排和协议联调，F 维护导出兼容性与媒体执行验收。六位同事分别拥有模块，不代表全组测试、运行和修复都交给最后一个人。

5.1 权责原则

- A 负责粗分段与源时间事实，D 负责入选区间的精剪。B 可以筛选和排序候选，但不擅自写最终成片时间。
- C 是故事及文案内容负责人；E 可以规范发音和标点，对事实/剧情的修改回交 C。
- D 是最终时间线的唯一编排者；E 提供声音事实，F 按时间线执行。
- F 遇到目标工程不支持的效果返回明确能力差异，不自行删字幕、烧平轨道或改故事。
- UI 初期复用现有 Gradio，由 D 接编排状态与编辑入口，F 接预览/工程下载；各模型同事不另做一套界面。
- 共享数据协议由相关生产者和消费者共同确认；D维护时间线协议，F负责确认其可导出性。

逐人 P0/P1、第一天任务、验收清单、跨模块问题负责人及交接模板见 六人任务书。

6. 独立并行开工：先统一合同，再替换真实上下游

先使用 黄金协议样例，它提供可解析的模拟数据，不包含可播放媒体，也不是当前 QuickCut CLI 已支持的新输入格式。这样 B 不需要等 A 完成所有索引，E 不需要等 C 完成所有模型规划，F 不需要等真实模型稳定。

共同字段规则：所有对象带协议版本、项目标识和修订信息；ID 区分 project、asset、segment、beat、cue、track；时间使用整数微秒，源时间与成片时间分开；区间采用左闭右开 [begin,end)；媒体以项目根目录下的相对引用交付，导出时重新定位。确切字段以 协议文档 和样例为准。

先约定四类失败的归属：没有候选交回 C；没有真实关键帧交回 A；配音超时交回 D/C；工程不兼容交回 F。重试要写明次数、使用的输入版本、变化内容和最终状态，不允许无限循环或静默降级为“成功”。

6.1 第一轮任务，不需要等待别人完成

同事	立刻可做的事情	第一份交接
A	用 3 个短片、1 个长片和 2 个空镜验证导入	可追溯 Manifest 和预览关键帧
B	用样例 Manifest 与手写请求实现召回	用户镜头和空镜分开的 CandidateSet
C	用固定候选和 Brief 输出故事板	有证据、预算和缺口的 StoryPlan
D	用手写故事板编译多轨时间线	时间校验通过的 EditTimeline
E	用手写句子完成本地 TTS	独立 WAV、实测时长和字幕
F	用手写时间线做最小剪映工程	两个视频、可编辑文字、独立音轨的实机记录

F 的实验必须最早进行，记录剪映版本、系统、操作步骤与失败原因。生成了一个 JSON 文件不等于能在剪映打开；目标软件版本是否支持，必须以实机结果为准。

6.2 三次汇合与共同里程碑

里程碑	可以宣布完成的条件
M0 协议与准备	相关同事确认 v0.1 输入输出；黄金样例可校验；确定目标剪映版本；有每人可独立运行的开发入口
M1 模块独立	每个模块通过自己的标准样例，返回正确数据或明确失败；F 已实际验证最小可编辑工程
M2 真实串联	多源素材 + 外部空镜 + Brief 经真实检索、规划、TTS、时间线和导出生成一个完整工程；所有产物引用一致
M3 编辑闭环	替换、重排、改单句配音会触发正确局部重算；剪映打开、编辑、保存、再导出；用户可以接手精修

这些是验收顺序，不是未经估算的日历承诺。各人完成 M0 实验后再估算工期和机器资源；剪映格式验证与模型中文效果验证应作为最先暴露的外部不确定项。

7. 验收：需要看到什么证据

类别	最低验收内容	主责
素材	混合长短、横竖屏、含音轨/无音轨均可处理；重复文件可识别；所有区间回到正确源文件	A
检索	中文/英文语义请求、ASR请求、空镜请求各有人工标注相关集合；记录召回与排序，不能只证明返回了列表	B
故事	每个关键事件有素材依据；空镜职责明确；无素材缺口被隐瞒；旁白没有角色颠倒或虚构结局	C
精剪	不越源边界、不出现非法同轨重叠；动作和话语有完整上下文；时间修改能追溯和撤销	D
声音	中文可懂、音色符合样例目标、单句可重做；文字与播音一致；超时可反馈；结尾不被截断	E
渲染	全量解码无错误；画面正常；时间戳一致；原声保留；旁白清楚；限制峰值	F
工程	在明确版本剪映中打开；可分别修改画面、文字、配音、音量；素材包移动后能重定位；保存后再次打开与导出	F，D配合
闭环	修改一个镜头或一句旁白后，旧缓存不会错误覆盖新 revision，只有依赖该修改的部分重算	D，所有相关模块配合

每轮使用三类真实测试集：单长视频、多短视频、长短混合；并覆盖无对白、画幅混合、候选不足、空镜不匹配、语音超时、最后一句、用户修改和素材路径变化。协议黄金样例只测试数据关系，不能替代真实媒体和剪映实机验收。

检索质量阈值、VLM语义正确率、自然语速范围和性能预算，应在标准测试集上实测后由模块负责人提出，再由消费者确认。不要把未测量的吞吐率、模型能力或自然度评分写为既定保证。

8. 从现有代码迁移，而不是一次性重写

1. **先增加新数据模型与旧格式适配器。** 旧时间线保持可读，新多素材时间线显式区分 asset 和 segment。用现有单源结果做回归基线。
2. **把单文件媒体能力抽成可重用函数。** A 扩展资产目录，F 让渲染按片段自己的 asset 引用取文件；代理与源文件时间映射由 A/D共同验证。

3. **为 B/C/E 加稳定输入输出边界。** 模型推理逻辑可以复用，但其输出必须经契约校验；不要让下游直接解析模型自由文本。
4. **让 D 管理修订、依赖和最终保存顺序。** 故事、音频和字幕对齐后保存最终版本，供预览与工程共享。
5. **F 先验证最小工程，再扩大轨道能力。** 支持矩阵说明哪些对象可原生编辑、哪些不支持；无法满足基础轨道要求时不能宣布工程交付完成。
6. **把样例脚本中有效的验证方法逐步收回模块。** 保留原始模型响应和人工修订来源，把“对一个视频手工调通”转换成可重放的通用过程。

建议避免六人同时大改 core.py。各人新建职责明确的小模块，调用现有能力；D维护编排接口，最后做少量集成修改。代码落点的细化建议见各任务书，不代表这些目录现在已经存在。

9. 开发、交接与复现约定

- 分支按模块建立，例如 codex/ingest-multi-source、codex/retrieval-broll、codex/story-planner、codex/timeline-ir、codex/voice-package、codex/jianying-export。每次 PR围绕可验收的输入输出变化。
- 提交源码、配置、示例协议和必要的小样；模型权重与大型素材不进普通 Git。素材包需有获取方式和哈希记录，让队友能补齐文件。
- 每个交付包含：版本、输入样例、输出样例、运行命令、测试结果、已知限制、消费者需要调整的地方。
- 当前依赖多为最低版本范围，尚不是锁定的可重复环境；M0记录 Python、操作系统、FFmpeg、Ollama版本、模型标识/权重摘要和依赖清单。不要声称任意平台环境都已验证。
- 开发阶段可以联网安装依赖和下载权重，正式内容推理保持本地；离线测试前先验证缓存完整，不能把首次下载失败当作模型推理失败。
- 使用 CPU/mock 快速检查结构，再按需要调度本地 VLM/TTS 集成测试。共享机器同时跑多个大模型任务时，由 D 的编排配置控制并发，不通过复制更多服务解决资源冲突。
- 当前命令、API以及平台差异以 基线文档 为准。新协议样例不直接传给旧版 quickcut render。

10. 需要记录的设计决策

决策	当前结论	后续如何改变
用户故事何时进入	输入时形成初稿，粗筛后做二次对齐	C 提供新规划策略及对照样例
外部空镜何时加入	粗筛时参与联合召回，二次对齐确定职责，再按缺口补充检索	保留其来源和使用目的
谁修改全局时间	D 唯一编排，E提供实测，F执行	契约变更由相关消费者共同确认
默认推理位置	本地	用户要求改变后再新增部署决策
CLIP与VLM关系	CLIP做召回，VLM做有限候选理解与选择	用质量/成本实测决定是否更换实现
旁白配音方式	逐句音频、真实时长、可局部重生成	更换TTS引擎不改变VoicePackage
剪映交付形式	可编辑草稿 + 素材包，先实机验证	不预设不存在或未验证的通用格式
成功的判定	技术可执行、故事可理解、工程可精修	不能只用JSON通过或MP4存在判定

11. 术语对照

术语	在本项目中的意思
Brief	用户希望成片讲什么、给谁看、是什么风格和限制
Asset	一份可定位的原始媒体文件或生成音频；不同于文件内部镜头
Segment	某资产上的源时间区间；可能是粗窗口、场景或精剪片段
Event / Beat	事件是素材中的活动；Beat是成片叙事段落，两者可多对多
B-roll / 空镜	用于环境、连接和情绪表达的辅助画面，其来源需要保留
CLIP	用图文向量相似度召回素材的模型；不负责语音时间同步
ASR	把原声或验证用音频识别成文字及时间戳
VLM	结合图像和文字理解候选，提出镜头与故事建议的模型
TTS	将已经确定的文字合成为声音
IR / EditTimeline	不依赖剪映私有格式的统一多轨时间线
Exporter	把统一时间线转换为目标工程和媒体包的适配器
Revision	一次明确修订版本；用于判断下游声音、字幕、渲染是否过期

本文确定共同方向；具体字段以协议为准，任务验收以六人任务书为准，当前已实现行为以代码基线为准。三者有冲突时记录差异并修订，不能把文档目标默认为运行时能力。

第二篇 现有 MVP 基线与技术选型

可编辑源文件：docs/team/mvp-baseline.md

审计日期：2026-11-06。代码基线：6cb978d（Add Chinese magnetic male narration summary video）。本文描述该提交的真实实现；团队指南中的多素材、外部空镜库、逐级精剪和剪映工程属于下一阶段目标。

本文供 A-F 六位同事确定起点、复用边界和迁移顺序。代码是事实来源；此前聊天中的旧视频、测试数量或音色描述不应覆盖当前源码和可追溯的成片记录。

1. 当前产品实际上能做什么

现有 QuickCut 是一个本地、单源视频的可运行原型。输入一个视频和一个文本要求，可以缓存视频索引，检索若干来源明确的片段，形成 5-60 秒时间线，再由 FFmpeg 输出视频。它已经包含 ASR、可选 CLIP、可选本地 Qwen 规划、基础时间线编辑、逐句本地 TTS、字幕与音频验证。

更完整的中文故事样例通过专用脚本完成：先审阅素材并确定三幕候选范围，再让 Qwen 在每幕中选取镜头，校验选片与排序；旁白经过画面对照修订，逐句生成配音，最后验证视频、字幕与原声。这个样例证明关键技术能够协作，但仍有显式人工编辑配置，不代表任意输入都能全自动得到同等结果。

能力	当前状态	事实依据与限制
一个长视频的索引、检索、剪辑	已实现	IndexManifest 和 Timeline 都只有一个 source_video
多个短视频、多个长视频共同编排	待实现	当前 asset_id 在多数路径中实际保存单源 shot_id，缺少全项目素材注册表
固定窗口粗分段	已实现	默认 3 秒窗口、3 秒步长，中点抽一帧；不是场景或动作边界检测
真实关键帧缓存	已实现	缓存复用前检查 PNG，VLM 输入前进一步解码验证；抽帧失败报错
Whisper 原声转录	已实现、可选	默认库接口不开启；显式选择 faster-whisper 时失败会暴露
CLIP 图文语义检索	已有可选适配器	默认和已审阅中文样例使用颜色直方图，不能把样例效果归因于 CLIP
外部空镜库与联合召回	待实现	external 仅存在于来源枚举；没有外部库导入、索引、检索和混合渲染闭环
Qwen 真实看图选择镜头	已实现、可选	候选关键帧带 ID/源时间；严格校验来源、数量、预算和三幕关系
逐级事件→镜头→边界精剪	待实现	通用路径仍以固定窗口和规则补齐为主，没有完整层级式细化
逐句中文配音与字幕定时	已实现	macOS say，中文默认 Reed，逐句 WAV 测量和时间适配
replace / trim / reorder	已实现基础操作	不会自动重建故事、旁白、字幕或刷新所有派生结果
剪映可编辑草稿导出	未实现	MP4 和 SRT 是媒体产物，不等价于剪映多轨工程
通用任务队列、断点续跑、模型调度	待实现	FastAPI/Uvicorn 是入口层；当前重任务主要在请求或脚本中同步执行

主要依据：数据结构、核心索引与剪辑、故事规划、中文样例说明。

2. 两条现有处理路径必须区分

路径 A：通用 API / CLI / Gradio 原型

单个源视频
→ build_index：固定窗口 + 关键帧 + 可选 ASR + 向量缓存
→ localize：视觉匹配 + transcript 关键词匹配
→ Timeline
→ 可选 basic 故事规划
→ trim / replace / reorder
→ render 或 render-story

- CLI 的 basic 和 API /basic 调用 build_basic_vlog；planner=ollama 才会显式使用本地 Qwen。默认 planner 是 deterministic。auto 遇到模型不可用或非法响应可降级，不能将降级输出统计为一次成功的 Qwen 决策。
- Gradio 的 Index + localize 调用的是 build_index → localize，没有调用 build_basic_vlog。勾选 Local narration 只控制渲染已有旁白，不能代替故事生成。
- 通用故事构建器仍保留按源时间修复顺序、填充邻近窗口、重新分配三幕和模板补文的代码。即便 plan_with_ollama 已严格校验原始响应，后续构建器仍可能调整它。因此不能笼统声称通用成片顺序完全来自 Qwen。
- localize 低分时返回 coverage=abstain，但 basic 可以继续使用规则回退镜头。团队下一阶段应把“拒绝、降级、需要更多素材”作为明确状态。

入口：CLI、API、Gradio。

路径 B：已审阅的中文故事样例

重新索引真实素材
→ 审阅候选区间、三幕和关键因果镜头
→ 每幕一张编号接触表，分别调用 Qwen
→ 校验选片；必要时让 Qwen 自己修正遗漏和顺序
→ 保存模型原文、图片哈希和纠正过程
→ 对照画面编写/修订中文句子与时间区间
→ 逐句 TTS，保存实测定时后的时间线
→ 原声参考、字幕烧录、配音混音、成片验证

这里的三幕配置与旁白不是自动生成后未经审阅就交付。act_config.json 明确规定候选区间、每幕数量和必选关键窗口；editorial_cues.json 明确保存画面对照后的中文文案与字幕区间。重新运行模型可能选择不同镜头，因此必须重新审阅 cue 是否仍匹配，不能把旧 cue 无条件套到新选择上。

仓库记录的样例为：源素材 212 个真实关键帧，39 个候选窗口，三幕选择数 6 / 8 / 6，共 20 个窗口，成片 58.5 秒。三幕配置共指定 9 个必选关键窗口。它使用 fallback-color-histogram 索引；ASR 没有识别到可用源对白。模型看图和人为故事约束才是这个样例叙事组织的主要依据。

该路径拒绝非法、重复、越界或遗漏关键事件的选择，保留模型的纠正记录；没有通过静默补片来伪装成完整模型方案。它是下一阶段 C/D/F 最值得复用的可追溯实现。

文件：样例工作流、分幕模型规划、三幕配置、审阅后的旁白、保存的模型选择记录。

3. 真实技术选型与默认值

下表记录源码中当前配置，不是对未来模型效果的承诺。新增模型时应保留旧适配器供回归比较。

模块	当前技术	默认 / 样例参数	负责同事
Python 包	setuptools、dataclass	声明 Python >= 3.10，包版本 0.1.0	全员；D 管理协议迁移
媒体处理	FFmpeg；可回退到 imageio-ffmpeg 自带二进制	关键帧宽 256；渲染 H.264、yuv420p	A / F
默认视觉特征	Python 颜色直方图	64 个 RGB bins + 8 个亮度 bins	B
可选语义视觉编码	OpenCLIP + PyTorch	MobileCLIP-S2，pretrained=datacompdr	B
原声 ASR	faster-whisper	tiny、cpu、int8、beam 1、VAD 开启	A
本地 VLM	Ollama HTTP 接口	qwen2.5vl:3b，默认 http://127.0.0.1:11434	C
VLM 视觉输入	Pillow 接触表 / 单帧	通用接触表默认 12 格；专用分幕每次 1 张，最多 24 格	C
输出约束	JSON Schema + Python 二次校验	允许的 shot IDs、数量、预算、三幕分区	C / D
本地 TTS	macOS say，无 say 时尝试 espeak	中文逐句默认 Reed (中文（中国大陆）)、rate 145	E
字幕	SRT + FFmpeg libass	当前中文样例使用 PingFang SC	E / F
音频中间格式	PCM WAV / MKV	48 kHz；配音单声道、原声参考立体声	E / F
最终音频	AAC	48 kHz、双声道、192 kbps	F
服务入口	FastAPI + Uvicorn	本地 HTTP API	D
工作台	Gradio	单视频、基础编辑和渲染	D
配音覆盖检查	本地 faster-whisper	样例使用 small、中文、词时间戳	E / F

OpenCLIP 适配器使用归一化图像/文本向量和余弦相似度；当前代码没有显式 GPU 迁移或向量数据库。auto 可以回退为直方图。颜色词典主要是英文，无已知颜色词时 fallback 给固定低分，不能将中文输入支持理解为中文语义检索已完成。

当前融合分数是：

$$\text{score} = \text{visual_score} + 0.35 \times \text{query_token_overlap_with_transcript}$$

transcript 项是词面交集，不是文本语义模型，也没有专门中文分词。threshold=0.22 是现有默认参数，不能未经验证直接跨模型复用。

VLM 读取关键帧，不是完整连续视频；对动作方向、角色关系、因果结果仍可能判断错误。格式校验通过只能证明返回数据可执行，不能证明叙述正确。

来源：依赖声明、视觉编码、ASR、VLM、声音处理。

4. 逐句配音与原声处理的可复用能力

当前 synthesize_timed_narration 已经能将每句 TTS 合成独立 WAV，去除首尾静音，测量真实时长，再用保持音高的 atempo 适配目标区间。默认句末停顿为 0.18 秒。每句的原始时长、tempo、实际放置区间与 speech end 写入故事元数据。

若字幕文本拼接后与旁白完全一致，函数保留这些显式 cue 的视觉时间安排；否则按每句语音的实测长度分配总时长。不能把这一步理解为已自动理解动作并完成语义对齐：显式 cue 仍需要 C/D 的故事板依据。

当前混音保留原声，固定增益 0.30；旁白归一化到 −18 LUFS，再与原声混合并限幅。片段中间音频使用 PCM，减少每个剪辑点引入 AAC priming 的问题。剪辑、拼接、字幕和混音阶段都统一处理时间戳。

下一阶段 E 应把音色、时长、音频和字幕作为独立 VoicePackage 输出；D 决定成片时间，F 执行混音和导出。当前函数直接修改 Timeline.captions 和 Timeline.story 的副作用需要在迁移时明确处理。

当前没有配音节奏异常的完整业务决策，例如超长句子应改文案还是延长镜头；也没有独立角色声线、对白口型同步、音乐自动选曲或复杂音效设计模块。

5. 文件到六人职责的映射

“主责”表示建议的下一阶段维护归属，不意味着现在应由多人同时编辑同一个文件。

现有文件	可复用内容	建议主责	迁移时注意
core.py 的 probe / index	探测、抽帧、缓存、转录关联	A	从单文件拆成素材注册与项目聚合；代理素材另建引用
asr.py	本地 ASR、sidecar、时间关联	A	输出语言、模型版本、失败状态；与媒体缓存分开失效
encoder.py	直方图、OpenCLIP 适配器、向量归一化	B	同一索引必须使用一致编码器指纹；评估中文召回
core.py 的 localize	基础召回和排序	B	增加联合素材池、外部空镜、结构化检索需求
vlm.py	视觉 payload、约束生成、模型证据、严格校验	C	保留原始响应与模型决策；区分人工规则与模型输出
story.py	通用故事构建原型	C / D，先拆接口再分别维护	规则排序、补段、文案模板属于历史实现，不作为新架构默认行为

现有文件	可复用内容	建议主责	迁移时注意
plan_summary_acts.py	分幕看图与模型自纠正	C	将硬编码三幕/本地字体/模型参数改为配置；保留证据
types.py	当前数据类	D	新协议版本与旧 JSON 适配，不能直接改变字段含义
ui.py、api.py、cli.py	基础入口与编辑交互	D	接入新编排服务；编辑后重新计算受影响派生物
voice.py 的 TTS / timing	本地逐句语音、WAV 时长、字幕	E	合成结果独立交付，明确语速过度调整状态
core.py 的 render、voice.py 的 burn / mix	画面编码、原声保留、字幕烧录、混音	F	每个片段按 asset_id 解析源文件，支持多源规格归一化
verify_chinese_summary.py	流信息、解码、字幕、原声回归验证	F	扩展多素材、草稿导入/重定位验证
check_narration_coverage.py	已知末句与词时间戳检查	E / F	不把 Whisper 幻觉尾句作为覆盖成功

6. 新同事的最小启动顺序

以下命令在仓库根目录执行。优先沿用团队已有虚拟环境；新机器可自行创建 .venv。依赖文件目前主要使用版本下限，没有完整锁文件；第一次成功安装后应记录解释器、库版本、FFmpeg build 和模型版本，供其他同事复现。

6.1 先跑不依赖模型权重的链路

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install -e '.[server,runtime,ui,dev]'
QUICKCUT_ASR=none python scripts/smoke_demo.py
python -m pytest -q
```

smoke_demo.py 自己生成简单颜色视频，验证“索引-检索-改剪辑点-渲染-不支持请求”链路；它不能验证真实语义、故事质量和中文声音。模型响应的单元测试主要通过 mock 验证接口与约束；真实模型质量需另外验收。媒体测试依赖相应本地二进制和 Python 库，实际执行结果以测试输出为准。

启动现有界面或 API：

```
python -m quickcut.ui
uvicorn quickcut.api:app --host 127.0.0.1 --port 8000
```

两条服务命令分别在终端运行。Gradio 当前仍是单源检索工作台；API 提供 /index、/localize、/basic、/edit、/render 和 /render-story。

6.2 启用 ASR、真实 VLM 和可选 CLIP

```
python -m pip install -e '.[asr]' 'pillow>=10' numpy
ollama pull qwen2.5vl:3b
```

先确保 Ollama 本地服务可访问；安装和拉取权重需要网络，完成后推理可以本地执行。Whisper 首次运行也可能下载权重。离线模式只适用于模型已缓存的机器。

基础真实素材命令（先把自己的视频放到 inputs/source.mp4）：

```
quickcut index inputs/source.mp4 --cache-dir cache --encoder fallback --asr faster-whisper
quickcut basic inputs/source.mp4 'a complete forest journey 45 seconds' \
 --cache-dir cache --encoder fallback --asr faster-whisper \
 --planner ollama --duration 45 --timeline outputs/basic.json \
 --render --output outputs/basic.mp4
```

这条通用命令可能因严格模型校验失败而报错，应该查看真实响应或缩小候选，不应为了“演示成功”静默编造镜头。中文故事的受控复现请按中文样例说明运行。

需要测试 CLIP 的同事另外安装并显式选择编码器：

```
python -m pip install -e '.[ml]'
quickcut index inputs/source.mp4 --cache-dir cache-openclip \
 --encoder openclip --asr faster-whisper --force
```

不同模型配置暂时使用独立缓存目录；不要用 fallback 索引直接执行 OpenCLIP 检索。实际权重名或平台兼容性有问题时，应记录失败并调整配置，不得悄悄把 fallback 成绩当成 CLIP 成绩。

6.3 环境与平台限制

- pyproject.toml 声明 Python 3.10 以上；当前开发机的 .venv 使用 Python 3.14，不代表所有可选依赖在所有 Python 版本都已测试。新同事应以团队跑通的环境矩阵为准。
- Python 依赖由 extras 安装；Ollama、FFmpeg/ffprobe、macOS 语音与系统字体不由 pip install 一并提供。all extra 不包含 dev 测试依赖。
- 基础 FFmpeg 可以来自 imageio-ffmpeg；字幕烧录必须有 libass subtitles filter。严格验证脚本需要真正可执行的 ffprobe，不能只依赖媒体时长正则解析。
- Reed 中文男声属于 macOS；Windows/Linux 路径会尝试 espeak，但声音效果不能自动视为等价。下一阶段 E 必须明确支持的平台与替代本地 TTS。
- 已审阅分幕脚本使用 macOS Arial 字体路径，字幕样例使用 PingFang SC；迁移平台时需要配置字体。该脚本尚未实现完整跨平台封装。
- inputs/、outputs/、cache/、tmp/ 和视频文件受 .gitignore 排除。仓库克隆得到代码与样例配置，不会自动获得原视频、模型、缓存或此前成片。

7. 当前缓存、时间线和编辑中的迁移陷阱

1. **单源 ID 不能直接当全局素材 ID。** 当前所有片段都从 Timeline.source_video 截取，渲染器不根据每个 item 的 asset_id 寻找不同文件。需要素材注册表后才能支持多源；先合并视频再冒充一份源会损失独立来源与精修能力。
2. **缓存指纹不够完整。** 现有 index_id 包括路径、大小、mtime、窗口/步长、encoder 名和 ASR backend 名，但没有完整 CLIP checkpoint、ASR model、语言或预处理版本。换模型/参数时应显式重建；A/B 应新增完整算法指纹。

3. **时间单位与轨道结构是旧约定。** 现在是浮点秒、顺序列表，duration 为各 item 长度之和；还没有独立轨道、输出位置、转场重叠或素材映射。新协议的整数时间和多轨结构需版本化转换，不能对旧字段直接换单位。
4. **精剪后派生物会过期。** update_timeline 修改 items，但不更新 story、narration、captions。D 应建立 revision 和局部失效机制，E/F 拒绝使用旧 revision 的结果。
5. **通用 CLI 保存时间过早。** basic 在 render_story_timeline 前写出 JSON；TTS 会在渲染期间更新字幕与音频时序元数据，因此该 JSON 未必包含最终语音时序。专用中文 render 脚本在逐句合成后保存，后者应成为新版的交付方式。
6. **模板补文不等于故事完整。** 通用 _complete_narration 仍有文案长度和模板填充逻辑，可能生成“开场交代环境”这样的制作说明。C 的新故事板应直接围绕画面与用户意图写脚本，E 应允许时长反馈，不靠无信息句子撑满一分钟。
7. **片尾过滤目前不是分类模型。** 通用路径使用 max(总时长×80%, 总时长−120s) 的尾段规则；专用样例使用审阅过的 494 秒边界。这不能直接迁移为任意素材的片尾事实。
8. **画面和语音覆盖需要分别验证。** PTS=0 证明时间起点一致；音频流存在不证明原声还在；Whisper 最后一个时间戳不保证最后一句真实存在。F 要保留原声参考与独立旁白，E/F 检查已知末句，C/D 检查画面语义。
9. **JSON Schema 约束不是理解能力。** 模型可以合法返回 ID 却误认角色或遗漏因果。VLM 的原文、实际输入图片、人工约束和后续修订都应可追溯。
10. **当前在线入口还是原型。** API 上传与渲染主要同步处理，尚无任务状态、取消、容量控制或用户隔离；不能仅因使用 FastAPI/Uvicorn 就称为生产级推理平台。

8. 下一阶段的复用建议

保留旧链路作为回归基线，将现有函数封装为新模块适配器，再迁移数据协议。优先复用关键帧校验、ASR、视觉编码适配、Qwen 证据记录、逐句配音和音频验证；重点重构多素材注册、层级分段、结构化需求检索、时间线编排以及可编辑工程输出。

先让一份人工编写的多源故事板能够通过 D/E/F 输出可编辑工程，再把 C 的模型结果替换进去，能让“模型效果”和“工程是否可执行”分别被验收。B 的空镜库同样应先以可追溯的静态候选接入，再逐步提高自动召回质量。

本次基线文档没有重新运行模型或修改运行时代码。历史样例的 82 项测试与音视频指标来自已保存样例说明；本轮指南发布时的实际测试结果由主文档的验证记录另行说明。

第三篇 六人实施任务与交接

可编辑源文件：docs/team/workstreams.md

版本：规划稿 0.1。更新日期：2026-11-06。代码基线：6cb978d。

本文把已经确认的产品结构拆成六份相对独立的工作。它描述的是下一阶段的实现目标，不代表多素材、外部空镜库和剪映工程导出已经完成。当前代码能力见 MVP 基线审计，总体工作流见 项目指导文件，数据约定见 模块交付协议。

1. 我们共同交付的是什么

用户先告诉系统想讲的故事、成片类型、语言、时长和风格，再上传一组长短不一的视频。系统需要从这些素材里找出有用的事件和视角，结合外部风景空镜安排环境交代、转场和留白。经过从素材级、事件级、镜头级到边界级的逐级收敛，生成故事完整、声音与画面对应的可编辑时间线，最后交付预览视频与剪映草稿工程。

工程交付必须保留可独立编辑的画面、空镜、原声、配音和字幕；如使用音乐，也保留其独立引用。主画面与空镜可以在同一画面轨道上使用不同 clip 和 role 表达，不强制空镜另占一条轨。预览 MP4 用于检查，不能替代可继续精修的工程。这里的“外部空镜”和“外部配音”表示它们不是用户原视频的一部分；模型推理和配音合成仍在本地执行。

六个人不按“各自做一个模型”分工，而按稳定的输入输出分工。任何人都应该能用手写样例运行自己的模块，不必等前一个人把模型完全做好。模型效果提升、媒体处理、工程导出因此可以同时推进。

2. 六个模块与边界

角色	一句话目标	主输入	主交付物	主要接收方
A：素材接入与索引	把一组原视频变成可追溯、可检索的素材集合	用户视频、外部视频文件、处理配置	AssetManifest 与代理视频、关键帧、ASR 文件	B、D、F
B：检索与外部空镜库	根据叙事需求找到合适且可用的候选片段	AssetManifest、RetrievalRequest	CandidateSet	C
C：故事与视听规划	让用户想讲的故事和真实素材能够对应	Brief、CandidateSet、视觉证据	StoryPlan、新的 RetrievalRequest	B、D、E
D：精剪与时间线编排	将故事板变成唯一、可执行的成片时间安排	StoryPlan、AssetManifest、VoicePackage	EditTimeline、修订请求	E、F、C
E：本地配音与字幕	将确定的台词变成可独立替换的声音和字幕	配音句子、句子预算或目标区间、声音配置	VoicePackage	D、F
F：渲染与剪映交付	按时间线生成可播放预览和可继续编辑的工程	EditTimeline、素材引用、VoicePackage	ExportManifest、工程包、预览和验证报告	全组、最终使用者

必须区分两个时间坐标：源时间回答“从哪份原视频的哪里取素材”，成片时间回答“这个片段何时出现在最终视频中”。新协议统一使用整数微秒与半开区间 [begin, end)；原代码中的秒浮点值通过兼容适配器转换，不可在同一字段内混用。

项目标识使用 project_id；素材、片段、故事段、配音句子和轨道分别使用 asset_id、segment_id、beat_id、cue_id、track_id。具体字段和必填约束以协议文件为准，不由各模块自行增加同义字段。

决策权

- A 维护素材事实：原始文件、时长、视频参数、源时间、关键帧和识别结果。
- B 维护检索结果：候选、分数、召回依据、过滤结果；B 不决定故事结局。
- C 维护叙事和事实表达：段落目的、镜头职责、关键事件、旁白文本、缺口处理。
- D 是成片时间线的唯一编排者：镜头与声音轨的最终位置、修剪、重排和版本更新。
- E 维护声音事实：实际合成音频、真实时长、音色、语速、字幕文本与句子对齐。
- F 按已经确定的时间线执行渲染和工程映射；F 不自行增删剧情、重排镜头或修改台词。

3. A：素材接入与索引

任务的意义

所有下游模块都必须知道素材真实存在，而且能够精确定位回原片。A 提供这一基础。对于多个短视频，A 既要保留每个文件的来源，又要提供可跨文件检索的统一片段集合；对于长视频，A 先做粗分段，不能把整个文件当成一个候选镜头。

范围与输入

输入是一组视频文件及其来源标记。A 负责媒体探测、文件身份与重复导入识别、代理视频、粗粒度场景或窗口划分、关键帧抽取、ASR、缓存、处理状态和失败重试。原片保持可追溯，代理视频不能覆盖原片。外部空镜文件也使用相同接入通道，但其库标签、语义索引和召回由 B 负责。

A 不负责故事顺序、最终出入点、CLIP 检索排名或对同一人物的长期身份作确定性判断。A 可以记录拍摄时间，但文件时间和镜头时间不能直接冒充跨设备的真实事件顺序。

可复用代码

- core.py：probe_video、extract_keyframe、build_index、缓存和 PNG 完整性检查。
- asr.py：本地 faster-whisper 适配、transcript sidecar、时间区间挂接。
- types.py：现有 Shot、IndexManifest 可作为迁移起点；目前不是完整多源协议。
- test_core.py、test_asr.py：基础回归样例。

P0：首个可联调版本

1. 接受文件列表，为每个文件分配稳定身份，并保留项目内来源引用。
2. 输出多素材 AssetManifest，区分文件、事件候选/粗段和镜头候选的层级；先允许固定窗口方案，明确标记分段方法。
3. 支持代理视频和关键帧；保存原片与代理时间对应关系，避免不同帧率导致取错片段。
4. 对有语音的素材运行本地 ASR；无音轨、无有效对白与 ASR 执行失败必须是不同状态。
5. 缓存绑定素材身份和处理配置，重复运行可复用；坏关键帧不能作为有效视觉证据交付。
6. 单个文件失败不应抹掉其他文件的成功结果，交付中标明可重试的失败项。

P1：后续增强

加入场景切换候选、音频停顿边界、基础模糊/曝光/静帧指标、增量索引与中断恢复。更细的动作出入点交给 D，不要求 A 对全片执行高成本 VLM。

第一份独立交付

第一轮使用三段短视频、一段长视频和两段空镜构造样例。即使 ASR 或视觉模型尚未准备好，也先用可解码的媒体和明确的空 transcript 跑通文件到 Manifest 的链路；测试中使用 mock 时必须标记，不能写成真实推理结果。

交给 B 的是 Manifest、关键帧和 transcript；交给 D、F 的是素材引用、源时间、媒体参数和代理映射。每份交付带一个可运行入口及示例输出。

验收与反馈

- 任取一个片段，能打开正确原片并定位到对应源时间。
- 混合长短视频、无音轨视频、不同分辨率/帧率视频均有明确处理结果。
- 相同输入和配置重复执行，素材身份不变化；新增文件无需重建所有旧文件。
- 缺文件、解码失败、ASR 失败、关键帧损坏能够返回到具体 asset_id 或 segment_id。
- 不向 B 交付“有 embedding 但图片并不存在”的视觉候选。

4. B：检索与外部空镜库

任务的意义

B 将“我需要一个交代清晨环境的镜头”变成可供 C 比较的真实候选。它既处理用户拍到的主内容，也处理库中的空镜，但始终保留来源区别。空镜可以承担开场、转场和情绪留白，不应因为颜色相似就被当成用户真实经历的证据。

范围与输入

输入是 A 的 Manifest 和 C 的 RetrievalRequest。每次请求应说明所属段落、镜头职责、内容要求和硬约束。B 负责图文向量、transcript 检索、外部库元数据、语义去重和候选质量排序。输出候选与依据，不输出最终故事结构。

空镜库的初始导入可以来自一组本地文件。跨互联网采购、无限自动下载和自动授权判断不属于首轮实现要求。库资产应记录来源引用及已知使用信息，便于 F 打包时保留出处。

可复用代码

- encoder.py：OpenCLIP/MobileCLIP 适配、归一化图文向量与余弦相似度。
- core.py：localize 和 transcript 词面重合评分可作为基线。
- test_encoder.py：现有编码测试。

当前 fallback 是颜色直方图与颜色词规则，不应作为 CLIP 语义检索的验收结果。现有中文 transcript 词面匹配也不能直接等同于中文语义检索。

P0：首个可联调版本

1. 接收统一 Manifest，为用户素材和外部空镜建立可区分的检索视图。
2. 封装可替换视觉编码器，记录模型名称、权重来源、特征版本和维度。

3. 组合视觉召回、transcript 召回、来源过滤和时长/画幅约束；不要将不同尺度的分数当作已校准概率。

4. 输出 CandidateSet，含候选来源、相关性依据、质量标记和未满足条件。

5. 支持外部空镜的场景、情绪、光线和镜头运动等标签；机器预测标签保留其生成方式。

6. 空集合是合法结果。没有合适素材时明确返回缺口，不用无关片段填满数量。

P1：后续增强

优化中文查询、近重复镜头聚类、多样性重排、镜头运动与色调匹配，并用带人工标注的查询集测量检索提升。检索请求可以按故事段落增量执行，不需要每次重算全部 embedding。

第一份独立交付

使用手写 Manifest 和本地小素材库，支持“用户主镜头”“环境空镜”“无匹配结果”三种查询。C 可以立即消费 CandidateSet，即使索引尚未来自 A 的自动流程。

验收与反馈

- 每个候选能够追溯到 A 的真实片段，不生成不存在的 ID。
- 来源过滤、时长/画幅等硬约束可重复验证。
- 同一个外部空镜不会因为重复导入挤占整个候选列表。
- 对事先标注的查询，报告召回结果和失败样例；首次协议会上确定统一的相关性评测集，不事后挑选成功示例。
- B 向 C 返回“找到什么、缺什么”；由 C 决定改写故事、换表达或发起下一次请求。

5. C：故事与视听规划

任务的意义

C 是用户意图与素材事实之间的协调者。它先根据 Brief 建立初始结构，再用真实候选核对这个结构是否可实现。它需要同时考虑主内容、空镜、旁白和原声，而不是把镜头选完后再拼上一段通用解说。

范围与输入

输入是 Brief、候选集、视觉证据及必要的 transcript。C 负责段落目的、关键事件、镜头职责、模型选镜与顺序、旁白脚本和段落预算；D 负责将这些安排落实到可执行的精细时间轴。

C 可以向 B 反复发起有明确目的的检索，但每次要记录缺口和调整原因，并设置有限的重试/规划次数。用户的故事愿望与素材可证实的事件应分别保存。外部空镜不负责证明用户素材中不存在的具体人物行为。

可复用代码

- vlm.py：真实关键帧接触表、Ollama 调用、ID 白名单、严格选择校验和推理记录。
- story.py：故事结构与候选准备的原型；需要区分模型决定与规则修正。
- plan_summary_acts.py：逐幕调用本地 Qwen、记录纠正过程的已审阅样例。
- act_config.json、editorial_cues.json：人工约束和人工文案的显式记录方式。

样例中的人工必选镜头和文案不是通用模型能力。迁移时保留其来源标记，不将人工编辑结果记录为未经干预的模型输出。

P0：首个可联调版本

1. 把 Brief 转成初始段落目的、关键事件、镜头需求和配音风格。
2. 为各段生成 RetrievalRequest，区分主内容、环境交代、转场和情绪留白。
3. 根据候选做二次对齐：可支持、部分支持、没有素材支撑的要求分别处理。
4. 调用本地 Qwen 选择实际可见的候选，输出顺序、理由和故事段归属。
5. 生成 StoryPlan，包含确定素材、可替换候选、空镜职责、段落预算和逐句旁白意图。
6. 为每个事实性描述保留对应素材证据；模型错误返回修正请求，不静默替换事件角色。
7. 保存原始响应、校验结果、人工修改和规划版本，支持比较两个故事方案。

P1：后续增强

同一素材的不同叙事风格、多方案比较、跨文件人物/地点的一致性核对，以及更少人工约束下的完整事件规划。角色对白配音与口型同步属于独立后续能力，不能以普通旁白模块的完成来验收。

第一份独立交付

使用一份人工整理的候选集，输出一个完整故事和一个素材不足的案例。先用固定模型响应测试校验器，再接入本地真实推理。C 不必等 B 的排名达到最终效果才开始规划接口。

验收与反馈

- 每一段有明确目的，每个选中素材 ID 都出现在候选证据中。
- 外部空镜的位置和作用可解释；故事不能靠重复空镜填满时长。
- 有叙事收束；素材不足时可明确请求补充、改写表达或缩减结构。
- 旁白内容与画面角色、动作和先后关系对照检查；自动格式验证不能替代内容审阅。
- 交给 D 的段落有预算和顺序，交给 E 的句子有 cue_id、beat_id 和表达要求。

6. D：精剪与时间线编排

任务的意义

D 把故事板编译成唯一可执行的时间线。粗粒度计划允许“这一段大约六秒”，但渲染和剪映工程需要精确知道每条轨道什么时候开始、什么时候结束。D 负责把模型的意图、素材边界和真实配音时长变成一致的成片安排。

范围与输入

输入是 StoryPlan、Manifest 和配音测量结果。D 负责选中片段附近的局部密集采样、出入点细化、动作/对白完整性、同轨冲突、节奏、镜头替换与重排、时间线修订、模块编排和端到端联调。

D 不重新识别整批素材，不自行更改故事事实，也不修改 TTS 音色引擎。镜头长度不足以承接旁白时，D 可以调整时间预算或请求 C 改稿；需要新增素材时向 C/B 发起请求。F 接收的是确定的时间线，不需要自行推断这些决策。

可复用代码

- types.py：现有 Timeline/TimelineItem 的迁移基础，当前 source_video 单源结构需要兼容升级。
- core.py：validate_timeline、update_timeline。
- ui.py：trim、replace、reorder 的交互与校验；现有逻辑不会自动重做完整故事和配音，需补齐失效传播。

- api.py、cli.py：现有调用入口，首版复用，避免另建一套无人维护的演示界面。

P0：首个可联调版本

1. 维护 EditTimeline 协议与旧 Timeline 的兼容适配，明确版本和源/成片时间转换。
2. 将 StoryPlan 编译成多素材、多轨时间线；每个 clip 都有稳定来源引用。
3. 在候选窗口附近细化入出点，优先保证动作或话语不被意外截断；精细模型未就绪时允许人工确认边界，并记录边界方法。
4. 生成给 E 的初始句子区间或预算，接收实测时长后完成第二次编排。
5. 检查源区间越界、非法同轨重叠、没有说明的空白和超预算。跨轨叠加与明确转场重叠不应误判为错误。
6. 保存时间线修订关系，编辑影响到哪些字幕/配音/渲染片段时，准确标为待更新。
7. 提供最小 orchestration 入口，串联 A/B/C/E/F；失败状态可定位到模块和输入版本。

P1：后续增强

镜头节奏优化、J-cut/L-cut、动作匹配、音乐节拍约束、细粒度局部重算和交互式候选替换。它们必须进入时间线显式表达，不能只存在于 FFmpeg 的临时命令中，否则剪映无法继续编辑。

第一份独立交付

使用手写 StoryPlan 和模拟的配音时长编译一条多源时间线。先验证普通时长，再把其中一句时长加长，确认只有受影响的区间发生可追溯调整。

验收与反馈

- 所有片段都有合法来源与源区间；可用数据解释每一帧/每个声音片段的来源。
- 原片帧率、代理帧率和导出帧率不同时，转换结果可验证。
- replace/trim/reorder 后字幕、配音和预览不会继续显示过期状态。
- 若音频无法适配视觉预算，返回明确的重定时或改稿请求，而不是让 F 裁掉末句。
- F 收到的冻结时间线必须精确引用所消费的 VoicePackage 版本；两类文档的 revision 数字无需相等。过期声音包应被拒绝或标记需要重算。

7. E：本地配音与字幕

任务的意义

E 将故事里的“应该说什么”变成可被剪辑系统使用的真实声音。语音是有实际长度和停顿的媒体，不是用字数推算后就能准确对齐的文本。E 必须交回声音事实，让 D 安排整条片子的时间。

范围与输入

输入包括 C 的逐句脚本、D 的预算或视觉区间、语言、音色、语速和表达要求。E 负责本地合成、逐句文件、真实时长、边界静音处理、字幕和声音质量记录。情绪配置要区分“接口允许指定”与“当前引擎确实支持”。

E 不替 C 改变剧情、事实或角色身份，也不自行移动整条画面时间线。外部配音与原声是独立轨道来源；最终原声、旁白和音乐的混合由 F 按 D 的时间线执行。

可复用代码

- voice.py：synthesize_local_narration、逐句 WAV 测量、synthesize_timed_narration、SRT、tempo fitting。
- check_narration_coverage.py：本地 Whisper 旁白末句检查。
- test_voice.py、test_summary.py：时序与媒体回归基础。

当前中文样例使用 macOS say 的 Reed 中文男声和语速参数 145。系统 TTS 的可用音色依赖平台，不应视为跨平台开放模型能力。首轮可以复用该实现，后续本地引擎通过同一适配接口替换。当前函数会回写 Timeline 的字幕与语音信息；新分工应改为显式返回 VoicePackage，由 D 应用更新，避免隐藏的时间线副作用。

P0：首个可联调版本

1. 封装本地 TTS 引擎接口，明确实际支持的语言、音色和表达参数。
2. 按 cue_id 合成一次并保存独立 WAV，记录文本、引擎、配置和真实时长。
3. 剪掉无意义的首尾静音，保留句内表达停顿；支持句末留白。
4. 区分“测量模式”和“指定区间适配模式”。超出可接受的语速调整范围时，返回 needs_retime，由 D 调整时间或 C 改稿。
5. 输出与播音文本一致的字幕及句子时间信息；不能把 ASR 猜测文本覆盖成最终字幕。
6. 单句文本或音色变化时可以只重做该句，并明确哪些后续对齐信息已失效。
7. 音频文件与字幕记录引用相同的已批准脚本版本。首次合成依据 StoryPlan revision 返回局部时序，不依赖已存在的 EditTimeline；D 发起指定区间重合成时，再携带并回显该请求的时间线 revision，避免混入旧版本声音或构造循环依赖。

P1：后续增强

本地神经 TTS 适配、音色试听与选择、多角色一致性、语气更自然的停顿控制和自动发音字典。是否实现某种情绪或声音特征应以实际试听和测量记录验收，不能只依据模型参数名称。

第一份独立交付

用三条手写中文句子生成配音：一条短句、一条正常长度句、一条故意超预算的长句。返回 WAV、实际时长、字幕与超时反馈，不等待最终 VLM。

验收与反馈

- 每句文本与音频对应，重复运行可追溯，不在切镜头时重复播音。
- 句子与字幕区间合法，实际末词不被截断；无声音与合成失败能够区别。
- 声音参数可复现；返回真实时长而非仅返回字数估计。
- 单句重生成后，D 能识别受影响区间；F 能保留独立配音轨。
- 无法在预算内自然表达的句子明确反馈，不用无限制拉伸或压缩掩盖问题。

8. F：渲染与剪映交付

任务的意义

F 将内部可编辑时间线交付到用户真正使用的编辑器中，同时产出预览让全组检查。目标是用户接手后还能改镜头、字幕和配音，而不是只能拿到一条已经烧录所有内容的 MP4。

范围与输入

输入是冻结版本的 EditTimeline、VoicePackage 和可解析的素材引用。F 负责 FFmpeg 渲染、原声/旁白/音乐混合、预览字幕、素材打包、剪映导出适配、实际打开验证和媒体质量报告。

F 不改变故事内容和全局时间，不能为了让文件导出成功而静默删掉不支持的轨道。目标编辑器不支持的效果需要在导出报告中明确列出，并交给 D/C 决定替代方式。

可复用代码

- core.py：render_timeline 的片段渲染、PCM 中间音频与时间戳处理。
- voice.py：字幕烧录、原声保留、旁白归一化、混音与峰值限制。
- verify_chinese_summary.py：解码、流时长、时间戳、字幕和原声保留的验证基础。

当前仓库尚无已验证的剪映工程导出。其目标版本、工程格式、路径规则和可用功能必须由 F 实机验证，文档不预设存在稳定的通用导入标准。

P0：首个可联调版本

1. **首先做最小导入实验。** 从一条手写时间线导出两段视频、可编辑字幕和独立配音；记录目标剪映版本和操作系统。
2. 实际打开、修改文字、移动镜头、替换配音、保存和重新打开；确认工程不是只有一个合成视频片段。
3. 建立编辑器能力映射：支持哪些轨道与属性，哪些必须拒绝或显式降级。
4. 将内部时间线映射为目标工程；媒体引用使用可打包、可重定位的机制。
5. 按同一 EditTimeline 渲染预览，保留原声和旁白的独立来源，避免预览与工程出现两套剪辑逻辑。
6. 生成 ExportManifest，记录输入版本、导出目标、文件清单、支持/未支持特性和验证结果。
7. 验证视频可解码、各轨时间一致、声音没有被丢弃、字幕与文字对象可编辑。

P1：后续增强

增加经过验证的转场、调色、音乐淡入淡出、速度变化和其他轨道属性；每新增一种效果，都分别验证预览结果与工程内编辑结果。跨编辑器适配可以后续增加，内部时间线不应被某个编辑器的私有字段污染。

第一份独立交付

F 不等待 A-E 完成。用标准素材和人工时间线做一个最小工程包，先完成实机导入。若格式路线不可行，应立即回报具体版本、失败步骤和功能边界，使架构能尽早调整。

验收与反馈

- 指定目标版本能够实际打开、编辑、保存和重新打开工程。
- 主画面、空镜、原声、配音、字幕保留可独立编辑性；字幕不能只存在于烧录画面中。
- 素材包移到新的测试目录后，能完成约定的素材定位或重链接步骤，并记录步骤。
- 预览与工程的顺序、入出点、文字和音频位置一致。
- 全量解码、时间戳与原声保留检查通过；只“生成了 JSON 文件”不算导入成功。
- 失败报告区分媒体损坏、时间线错误、缺失素材、模型产物不完整与目标编辑器不支持。

9. 第一轮共同准备：标准样例与接口冻结

在实现真实模型链路之前，六人共同确认一套最小样例。它的目的是给每个模块提供稳定输入，不是假装系统已经能自动生成这些数据。

建议样例包含以下内容：

1. 三段不同长度的用户短视频、一段用户长视频、两段外部空镜；至少覆盖一个无音轨文件和一个不同帧率文件。

2. 一份中文 Brief，明确一个可以由样例素材支撑的三段故事。

3. 手写的 AssetManifest、RetrievalRequest、CandidateSet、StoryPlan。

4. 几句真实可合成的中文配音文本、一份模拟 VoicePackage、一份手写 EditTimeline。

5. 预期行为说明：哪些候选应召回，哪些素材应被排除，哪个音频故意超时，哪些情况下必须返回缺口。

纯协议 JSON 样例不含真实媒体时，只能用于协议校验。媒体验收需要另行提供可播放的素材文件，不能把不存在的示例路径当成真实测试成功。

每个人负责自己输出协议的草稿，D 维护时间与 ID 的共同约定。字段改变必须同时通知消费者，并更新样例与校验器。新增字段优先采用兼容方式；改变单位、语义或必填条件需要明确升级协议版本。

10. 里程碑与汇合方式

下表是交付顺序，不是工期承诺。模型效果、硬件环境和剪映适配可行性确认后，再据此估算人日和排期。

阶段	共同目标	通过条件	尚不要求
M0：协议与样例	六人能对同一份数据说同一种语言	协议字段、ID、时间坐标、示例和失败状态一致；各人能读取自己输入	真实模型全部接通
M1：模块独立可运行	每个模块都有一个独立入口	手写上游输入可运行；有成功和失败案例；F 完成最小剪映实机导入	最终检索/叙事效果最优
M2：真实链路串联	用真实上游产物替换 mock	混合长短素材与空镜生成完整工程、独立配音字幕和预览；版本链可追溯	复杂特效、多角色口型同步
M3：编辑与异常闭环	人工精修不会破坏系统一致性	镜头替换/重排、旁白改稿、素材缺失、超时和迁移路径均有正确处理与回归	面向所有编辑器版本的兼容

每轮只替换一个明确的接口产物。例如 A 的真实 Manifest 替换手写 Manifest 后，B/C/D 的错误可以被定位到字段或素材，而不是一次替换所有模块后一起排查。

模型服务和本地硬件是共享资源。接口测试优先使用固定响应；真实 Qwen/TTS/ASR 运行记录模型与配置。多人共用同一台机器时，约定推理任务排队，避免互相触发内存压力后把超时误认为接口错误。

11. 跨模块问题由谁处理

现象	首要处理人	需要协作	预期处理
关键帧缺失或源时间不对	A	D	修复索引或时间映射，标记依赖产物失效
中文需求找不到相关素材	B	C	检查检索表示和约束，返回候选/缺口；C 决定调整结构
模型颠倒角色或虚构动作	C	B	对照证据纠正或重新规划，保留模型原始输出
旁白超出片段预算	D	E、C	先读取真实时长，再调整画面安排或要求改稿
TTS 发音、音色或停顿有问题	E	C	调整语音参数或规范化文本，保留原始台词语义
修改镜头后字幕仍是旧内容	D	C、E	触发相关段落和声音的失效/重算
原声消失、输出时钟不同步	F	D、E	对照时间线和独立音轨定位渲染/混音问题
剪映不能打开或轨道不可编辑	F	D	反馈目标版本和能力边界，修复映射或明确拒绝导出

12. 每次交付的共同要求

每个人交付的不只是代码，还包括接收方可以直接复现的输入输出。所有模块均应提供：

- 输入、输出协议版本及兼容说明。
- 一个可运行入口，区分真实模型模式与 mock/fixture 模式。
- 一组小型示例输入输出，媒体文件用明确引用，不能隐藏在个人目录中。
- 与改动相适应的自动化测试；真实模型结果另存复现命令、模型配置和原始响应。
- 成功、部分成功和失败的处理说明；错误要包含相关项目/素材/段落/句子 ID。
- 已知限制、下一位接收者，以及需要消费者确认的字段变化。

推荐每人使用独立的 codex/ 前缀分支或团队约定的隔离分支。共享协议和 types.py、core.py 等多人会触碰的文件，由实际负责的同事集中合并；其他人优先通过适配器调用，避免六条分支同时重写相同核心函数。

交付 PR / 交接说明模板

本次交付解决的问题：
负责模块与接收人：

输入：协议名、schema_version、示例路径、需要的媒体
输出：协议名、schema_version、示例路径
运行方式：安装前提、命令、真实模型或 mock 标记

已验证：
- 成功案例及结果
- 失败/缺口案例及结果
- 对时间、素材来源和依赖版本的检查

接口变化：新增/修改字段及消费者影响
已知限制：尚未支持的场景，不用成功样例掩盖
接收方下一步：应该运行哪条命令，检查哪些字段或媒体

13. 整体完成标准

第一阶段的共同验收输入，是一组长短视频、外部空镜库与一个用户故事要求。输出应是一条不超过已约定时长预算的完整故事：主内容有来源、空镜有作用、旁白与画面对应、原声被保留，且能在已记录的剪映目标版本中独立修改镜头、字幕和配音。

完成标准包含一次真实的人工精修：打开工程、替换一个镜头、修改一句字幕或配音、保存后重新打开并导出。这样才能确认六位同事的交付真正连接到用户的工作方式，而不止连接到一个演示 MP4。

第四篇 模块接口与交付契约

可编辑源文件：docs/team/contracts.md

日期：2026-11-06。状态：下一阶段设计提案。 本页定义六位同事并行开发时共同使用的数据语言；它尚未成为现有 QuickCut CLI/API 的实现。任何字段冻结和变更应由字段生产方、消费方共同确认。

现有单视频 Timeline 仍可用于 MVP 演示。多素材、外部空镜、多轨工程和跨模块修改的正确性，需要显式的素材身份、两套时间坐标和版本引用。这里不把剪映私有格式当作内部数据模型；F 单独适配目标剪映版本。

配套文件：

- 黄金样例说明
- 完整 JSON bundle
- 无模型校验器
- 六人任务书
- 现有 MVP 基线

1. 我们用这些数据共同完成什么

用户提供的是一组视频和一段成片要求。A 将素材变成统一资产与候选片段；B 根据 C 提出的需求召回用户素材与外部空镜；C 将实际可用素材对齐成故事板，并确定旁白文本；D 将故事板编译成多轨时间线；E 返回逐句音频和真实时长；D 决定最终声音与画面如何排列；F 按同一时间线生成预览和目标剪辑软件工程。

因此，这些契约不是八个新的微服务。首版可以在同一个 Python 项目中，以函数调用和版本化 JSON 文件交接；接口稳定之后再决定是否使用独立进程或任务队列。

对象	唯一生产责任方	消费方	代表什么
Brief	C，来源为用户输入	A/B/C/D/E/F 按需读取	主题、故事目标、风格、语言、时长与成片约束
AssetManifest	A；外部库元数据由 B 提供后按同一规范注册	B/C/D/F	真实素材与候选片段的身份、来源、时间、媒体参数
RetrievalRequest	C	B	每个故事段落需要怎样的主镜头或空镜
CandidateSet	B	C	检索返回的候选与证据；不决定最终故事
StoryPlan	C	D/E	叙事目的、镜头选择与建议顺序、空镜职责、旁白文本、时间预算
VoicePackage	E	D/F	逐句音频、实测时长、局部字幕与适配结果

对象	唯一生产责任方	消费方	代表什么
EditTimeline	D	E 按需读取、F	最终轨道、剪辑点、成片时序和渲染意图
ExportManifest	F	D、用户、验收人员	导出物与软件版本、素材打包信息、实际导入验证状态

外部空镜的目录维护、标签和检索属于 B；其媒体信息必须遵守 A 的资产格式。可以由 B 调用 A 的索引入口生成外部库索引，避免两套重复的元数据和时间规范。第一轮不强制把整座外部库复制进每个项目：只有入选素材进入交付包，并保留库条目的身份及来源信息。

2. 所有模块共享的基本约定

2.1 公共信封与精确版本引用

每份文档都有以下字段：

字段	类型与规则	用途
schema_version	字符串，当前提案为 0.1.0	表达字段结构版本，与项目内容 revision 分开
kind	八种文档名之一	让校验器和消费者知道对象类型
document_id	非空、稳定的字符串	文档身份，不随一次重新计算改变
project_id	同一项目全链路一致	防止串用其他项目的候选或音频
revision	正整数；内容变化即递增	对同一文档进行精确版本引用
fixtures_only	布尔值	夹具为 true；生产导出必须拒绝夹具数据
owner	A/B/C/D/E/F	明确写入责任
inputs	{kind, document_id, revision} 数组	记录本次计算消费了哪一版上游结果

示例：

```
{
 "schema_version": "0.1.0",
 "kind": "StoryPlan",
 "document_id": "story-001",
 "project_id": "project-forest-vlog-001",
 "revision": 1,
 "fixtures_only": true,
 "owner": "C",
 "inputs": [
  {"kind": "Brief", "document_id": "brief-001", "revision": 1},
  {"kind": "CandidateSet", "document_id": "candidates-001", "revision": 1},
  {"kind": "AssetManifest", "document_id": "manifest-001", "revision": 1}
 ]
}
```

模块不得只写“使用最新素材”。交接时必须携带精确 revision。上游内容已改变而旧结果尚未重算时，D 标记下游 stale 并阻止最终导出；不能因为文件名相同就继续复用。首版按整份聚合文档判定旧 revision 失效，但生成新 revision 时可以复用未变更的句子音频：E 根据 cue 文本、音色、引擎和适配参数确认复用条件，D 重新计算受影响的成片位置。整份旧 VoicePackage 被拒绝，不等于每句 WAV 都必须重新合成。更细的跨模块依赖图可后续扩展。

2.2 身份与层级

- asset_id：一个真实视频、音频或图片文件的身份。用户视频、外部空镜、生成配音共享这一概念；不能拿镜头 ID 代替文件 ID。
- segment_id：一个素材里的区间，必须同时引用 asset_id 和 asset_revision。粗事件可以通过 parent_segment_id 关联更细镜头。
- beat_id：故事段落的身份。与文件边界无关，一个事件可以跨文件，一个文件也可以包含多段事件。
- cue_id：一条被批准的配音句子的身份；脚本、WAV、字幕和时间线必须能通过它关联。
- track_id：成片中的画面、原声、旁白、字幕等轨道身份；clip_id 是轨道上的具体实例。同一素材在不同位置使用时创建不同 clip，不能复用同一 clip ID。

素材 ID 建议使用 UUID 或稳定命名的随机 ID；内容哈希用于去重和失效检测。素材路径不是身份，移动项目目录不应使故事引用失效。样例中的可读 ID 只是便于团队理解。

2.3 时间、帧率与变速

所有时间用整数微秒，所有区间为半开区间 [begin, end)。 不使用含义不明的 start: 3.0。

字段	坐标系
source_range_us	相对于所引用源素材起点
source_time_us	某张关键帧在源素材中的位置
timeline_range_us	相对于成片起点
local_subtitles[].range_us	相对于该句生成音频的起点
duration_budget_us	规划阶段的预算，不等同于已确定的成片区间

例如源视频 40-46s 的内容放在成片 9-15s：

```
{
 "asset_id": "asset-long-01",
 "source_range_us": {"begin": 40000000, "end": 46000000},
 "timeline_range_us": {"begin": 9000000, "end": 15000000},
 "playback_rate": {"numerator": 1, "denominator": 1}
}
```

帧率单独使用分子/分母，例如 30000/1001，不得截成整数 30。D 决定出入点的帧边界和误差容忍规则；F 转换为导出目标的 timebase，并记录发生的舍入。首版黄金样例使用固定 30 fps 和 1 倍速，满足：

```
源区间长度 × playback_rate.denominator
= 成片区间长度 × playback_rate.numerator
```

素材是 VFR 时，由 A 保留原始时间信息和代理映射，D/F 根据 PTS 而不是“帧号除以平均帧率”反算原片位置。变速画面对应的原声处理方式需要写进轨道策略，不能让画面变速而原声按另一套时间播放。

2.4 文件引用与来源

- uri 在这版契约中表示**项目根目录下的相对文件路径**，使用 / 分隔；不得写某位同事机器的绝对路径。
- 引用包含 asset_id、asset_revision，真实媒体带内容哈希。预览代理和原片分别记录；导出不能不经声明地拿低清代理代替原片。
- origin 为 user / external / generated。外部库条目保留库 ID、来源记录及可用范围，用户素材和外部空镜不能被混为“同一地点真实发生”的事件证据。
- E 的生成音频清单保存在 VoicePackage.assets，F/D 使用 A 与 E 两份清单的并集解析资产；ID 不得冲突。后续可以统一注册到项目资产仓库。
- F 打包时复制或明确引用实际使用的素材，生成重定位映射。是否复制整个源文件、是否使用可重定位链接由目标工程能力决定，必须写入导出报告。

3. 八个对象的最小字段

3.1 Brief：用户需求是整个流程的起点

requirements 至少包含 story、format（VLOG/微电影等）、language、target_duration_us、aspect_ratio、tone、narration、broll_policy、target_editor。constraints 记录本地推理、原声保留、可编辑轨道等要求。

用户的“希望讲述的故事”和素材已经发生的事实要分开。C 可以根据可用证据缩减、调整表达，并把无法成立的事件写入缺口；不能在生成脚本时把目标故事当成已拍到的事实。

3.2 AssetManifest：素材事实由 A 统一维护

字段	要求
assets[]	文件 ID/revision、类型、来源、URI、哈希、时长、视频宽高/fps、音频参数、代理路径
segments[]	区间 ID、asset 引用、源时间、颗粒度、父区间、关键帧与 transcript
quality	当前检查结果和明确 flag；缺失信息不能写成“通过”
embedding_profile	模型 ID、后端、向量维度及索引版本；实际向量可外置保存

切分由粗到细：文件 → 事件/场景候选 → 镜头候选。A 提供稳定的初步切分；D 只在选定内容附近进一步细化出入点。若 D 需要超出已批准的候选区间，应先生成新的区间引用并更新选择记录，不能让剪辑点悄悄扩展到未知素材。

3.3 RetrievalRequest：C 向 B 提出的需求

queries[] 每条包含 query_id、beat_id、semantic_text、镜头 role、allowed_origins、时间预算与 top_k。可扩展画幅、运动方向、光线、地点类别等过滤条件。iteration / max_iterations 显式约束检索循环。

建议的职责名包括 primary（人物/动作）、establishing（建立环境）、transition（转场）、atmosphere（情绪留白）、detail（细节）。职责比“随便找一段风景”更能帮助 B 返回有效空镜。

3.4 CandidateSet：召回结果不等于最终决定

results[] 必须逐条对应请求里的 query_id，即使没有结果，也要返回 status: empty 与原因。候选包含 candidate_id、segment_id、素材 revision、视觉/文字/质量分、综合排序分、来源和证据。

分数必须携带 score_profile 或模型/融合版本；颜色直方图、CLIP cosine 和关键词匹配不是同一统计分布。不得跨模型直接比较一个未校准的“0.8”。B 负责排序并提供候选，C 决定采用哪一个以及安排在哪里。

3.5 StoryPlan：可执行故事板

每个 beat 记录 beat_id、顺序、叙事目的、时间预算、选定镜头及职责、旁白句子 ID。每个 shot 同时引用候选 ID 和片段 ID，便于追溯召回与最终选用的关系。

narration_cues[] 包含 cue_id、beat_id、批准文本、时间预算、声音风格、证据片段 ID。unresolved_gaps[] 列出缺失人物/动作/结尾等问题，并明确解决建议。decision_provenance 记录使用的模型调用、规则调整和人工审阅，而不是把所有结果都标成“Qwen 自动选择”。

段落时间预算之和应符合 Brief 约束，但它不是最终时序。E 不以预算假装已经获得真实语音；D 可以在语音实测后重新分配段落长度。

3.6 VoicePackage：返回声音事实与时长问题

字段	要求
assets[]	逐句音频文件、音频格式、真实时长、内容哈希
cues[]	对应句子 ID、原文、所属段落、音频 ID、原始/处理后时长、局部字幕
fit_status	fits / needs_retime / failed
tempo_ratio	实际采用的变速比例；没有变速则为 1
needs_retime	声音无法在可接受语速下满足预算时为 true
synthesis_profile	引擎、模型/音色版本、语言、语速/风格、本地运行标识

E 不修改画面顺序，不编造语音时长，不自行截掉句尾。 若声音太长，返回实际 WAV 和 needs_retime；D 尝试调整镜头或空镜长度，若仍无法满足则交 C 缩短文案。字幕文本来自批准脚本，ASR 用于核验，不用识别错字覆盖脚本。

没有明确画面句子区间时，E 先返回句子自身的局部时序。D 把它映射到成片。若 D 已给出明确句子区间，E 应在本次生成请求中记录该区间和基于的时间线 revision，并在回复里回显；D 只接受与当前请求匹配的回复。这类重合成请求可作为任务元数据保存，不要求首版增加一个新的核心文档种类。

3.7 EditTimeline：D 是全局时序的唯一所有者

轨道类型	clip/cue 至少包含
video	clip ID、asset/segment 引用、beat ID、职责、源区间、成片区间、变速、原声策略
source_audio	源素材与源区间、成片区间、关联的画面 clip、增益
narration	cue ID、生成音频 asset 引用、源区间、成片区间、增益
subtitle	字幕 ID、cue ID、文本、成片区间、可编辑标识
music / sound_effect	音频素材、源/成片区间、增益与可选音量包络；首个夹具暂不包含

output 记录画幅、分辨率、fps、采样率；render_policy 区分“预览可以烧录字幕”和“工程导出必须保留文字轨”。静态增益、淡入淡出、ducking 等参数应作为显式意图，F 负责一致执行。

基础版本要求单轨无意外重叠，画面完整覆盖成片区间。跨轨并行是正常情况，例如画面与旁白；以后加入叠化时，需要明确 overlap/effect 语义及导出能力映射，不能让通用无重叠检查把合法叠化当作错误。

3.8 ExportManifest：不能把写出文件等同于导入成功

至少保存：输入时间线 revision、目标软件名称/实际版本/平台、适配器版本、工程根目录、文件清单、素材重定位映射、预览与编辑工程路径、警告与导入验证记录。

建议状态：not_exported → generated → verified_import，失败用 failed 并附明确原因。只有在指定剪映版本真实打开、编辑、保存，并检查素材路径后，才允许记录 verified_import。未支持的效果或轨道需显式报错或经用户选择降级；不能在导出时悄悄烧成一整段视频并声称“各轨可编辑”。

本仓库当前没有可用的剪映导出适配器，黄金样例中的目标版本为 UNVERIFIED。F 的第一项任务就是以两段画面、独立旁白和可编辑字幕做真实导入实验。

4. 黄金样例如何贯通六人交接

本例时长 18 秒，只用于让接口清楚可测，不是最终剪辑风格标准。

成片区间	画面来源	源区间	责任与声音
0-6s	短视频 1：出发准备	3-9s	主镜头；保留独立原声；cue-01 在 0.2-5.4s
6-9s	外部空镜 1：林间光线	2-5s	环境过渡；不声明为用户实际地点；该占位文件无音频
9-15s	长视频：人物步行	40-46s	主镜头；保留独立原声；cue-02 在 6.2-14.4s，跨空镜与动作镜头
15-18s	短视频 3：坐下休息	1-4s	结尾；保留独立原声；cue-03 在 15.2-17.4s

短视频 2 和外部空镜 2 是候选但未入选，说明“进入素材库”不意味着“必须出现在成片”。三个音频文件和字幕分别放在各自轨道，后续可以换一句声音、移动一条字幕或替换空镜。

执行：

```
python examples/team_contracts/validate.py --self-test
```

校验器使用 Python 标准库检查八份文档的引用与时序，并用五个负例确认能拒绝：陈旧 revision、目录越界、源区间越界、字幕文案不一致、虚假的导入成功声明。媒体文件不存在是夹具的明确属性；该校验器不检查真实模型推理或真实剪映格式。

5. 修改之后哪些东西失效

变更	应保留/复用	必须重算或复核	发起方 → 负责方
新增素材	旧素材索引与哈希	新素材索引、受影响候选与故事覆盖	A → B/C
原文件内容变化	不受影响资产	该资产索引、依赖它的候选/故事/时间线	A → B/C/D
故事目标或语言变化	原始素材索引	检索请求、故事、脚本、配音和时间线	C → B/D/E
替换镜头	无关镜头和 WAV	该段事件证据、旁白匹配、画面与原声区间	D → C，必要时 E
重排镜头	原始媒体、未改文本的配音文件	故事因果、字幕/声音位置、混音和导出	D → C/E/F
改一句旁白文本	其他句子的 WAV	对应 cue 合成、字幕、该区间时序	C → E/D
只换音色	素材选择与文字	音频实测、时间线适配、预览和工程包	E → D/F
调整画幅或导出软件版本	素材身份、故事文本	裁切策略、字幕布局、目标效果映射、实际导入验证	D/F

更新采用新 revision，不覆盖旧产物后声称缓存仍有效。建议运行目录按 project_id / stage / revision 保存，并记录输入哈希、模型参数、运行日志与错误；旧结果可以用于追溯，不能在当前工程里偷偷替代失败的新结果。

6. 有限反馈循环和失败结果

这部分是团队约定的建议默认值，不是当前运行时已有的自动重试机制。

B ↔ C：故事与素材二次对齐

1. C 发出分段检索请求，B 按原请求返回候选或明确空结果。
2. C 判断是否足以表达段落；不足时可以放宽非关键风格条件、调整叙述方式或安排有明确职责的空镜。
3. 默认同一缺口最多检索 3 轮；仍没有事件证据时，保留缺口并要求编辑决策，不能无限检索或编造人物行为。

D ↔ E：声音与画面对齐

1. E 逐句合成并返回真实时长。适配比例应在项目允许范围内；大幅变速必须被显式标记。

2. D 优先利用合理停顿、镜头延长或可用空镜调整区间。若需要改变事实和文案，交给 C。

3. 默认同一句最多自动适配 2 轮；仍超预算返回 needs_retime，停止该版最终导出并提供待处理 cue 列表。

模块统一错误信封（建议）

```
{
 "status": "failed",
 "code": "STALE_INPUT_REVISION",
 "stage": "timeline",
 "project_id": "project-forest-vlog-001",
 "message": "StoryPlan 已更新，本次配音基于旧版脚本。",
 "retryable": false,
 "affected_ids": ["cue-02"],
 "action_owner": "E"
}
```

错误码	含义	下一步负责人
MEDIA_UNREADABLE / KEYFRAME_MISSING	索引输入损坏或关键帧无法读取	A
NO_CANDIDATE	合法检索但没有候选，通常属于空结果而非服务崩溃	B 返回原因，C 决定调整
UNSUPPORTED_STORY_BEAT	缺少支撑具体人物/事件的证据	C
VLM_INVALID_PLAN	非法 ID、漏掉必需动作、超预算或错误结构	C
STALE_INPUT_REVISION	接口引用已过期或项目不一致	当前消费方拒绝，上游重算
TIMELINE_INVALID	越界、非法重叠、音画源区间不一致	D
VOICE_NEEDS_RETIME / TTS_FAILED	语音超时或生成失败	E 返回事实，D/C 处理时序/文案
EDITOR_VERSION_UNSUPPORTED / EDITOR_IMPORT_FAILED	目标工程能力或实际导入失败	F
PACKAGE_MISSING_MEDIA	工程引用缺失或素材移动后不可解析	F，必要时 A/E

不要把“返回了一个 MP4”当作所有错误已解决。流程状态必须区分可预览、仍需编辑和已通过最终交付验收。

7. 从当前 MVP 渐进迁移

当前模型见 quickcut/types.py：Timeline.source_video 是单一路径，TimelineItem.asset_id 实际上经常装的是 shot_id，start/end 使用浮点秒。多素材版本必须改变这些语义，不能只把 source_video 改成列表。

建议迁移顺序：

1. **建立兼容转换器和新契约样例。** 现有单视频 Manifest 注册为一个真正的 asset；旧 shot_id 转为新 segment_id；旧 item 的 asset_id 先通过 shot 查到源素材，再转换，不能直接当作新文件 ID。
2. **先将 D/F 的输入切换成显式多轨时间线。** 旧时间线的成片位置由各 item 的时长累加得到；原声拆成显式链接画面的音频轨；旧旁白和字幕转换成 cue 引用。
3. **接入 A/B 的多源索引和两类素材库。** 主素材与外部空镜都遵守统一资产结构，但保留来源角色，不把两类库的检索结果混为事实证据。
4. **接入 C 的两次故事对齐与 E 的逐句实测。** 淘汰“编辑 items 后保留旧字幕/旧文案不变”的行为；由 D 管理依赖失效与局部重算。
5. **F 实现具体剪映版本的导出适配。** 当前 FFmpeg 渲染能力可复用，工程文件生成与真实导入验证另建测试；内部契约不随目标软件私有字段变化。

迁移期间，两种版本分别标明，不让同名字段承担两种含义。M0 先通过黄金样例校验，M1 每个模块能独立消费/产生约定对象，M2 使用真实上游产物贯通，M3 再验收编辑后重算与剪映精修。

8. 协议修改与交接清单

- 生产方提交字段变化、迁移示例和受影响消费者列表；消费方确认后再合并。
- 字段新增尽量可选；改变 ID、时间单位或引用语义必须升级 schema 并提供转换路径。
- 每次交付提供一个无需模型的固定样例，以及一份真实运行结果。两者的 fixtures_only 与证据说明必须清楚。
- 交接时检查输入 revision、错误状态、媒体路径、时间单位、来源、文本与音频匹配，最后才检查视觉效果。
- 自动校验只证明数据满足约束；语义正确性、声音自然度与剪映实际可编辑性必须由相应模块的真实验证补充。

附录 协议样例的使用与验证

可编辑源文件：examples/team_contracts/README.md

这套文件让 A-F 六位同事在上游实现完成之前，使用同一份输入输出开发模块。它是下一阶段的**数据协议提案和离线测试夹具**，不是当前 quickcut CLI/API 已支持的格式，也不是可导入剪映的真实草稿。

bundle.json 封装八份相互引用的文档：Brief、AssetManifest、RetrievalRequest、CandidateSet、StoryPlan、VoicePackage、EditTimeline 和 ExportManifest。统一 schema_version: "0.1.0"、项目 ID、整数微秒和版本引用。设计说明见 接口协议。

样例讲述“离开城市，到林间散步，最后坐下休息”，包含 3 个短视频、1 个长视频、2 个外部空镜的元数据。最终时间线长 18 秒，包含主素材、空镜、独立原声轨、逐句配音轨和可编辑字幕轨。未使用的素材也保留在素材清单中。

检查样例

从仓库根目录运行，Python 3.10+ 标准库即可，无需下载模型：

```
python examples/team_contracts/validate.py
python examples/team_contracts/validate.py examples/team_contracts/bundle.json
python examples/team_contracts/validate.py --self-test
```

成功时输出 PASS: contract fixture ...。检查内容包括必需文档、版本引用、ID、整数时间区间、素材范围、候选与故事引用、时间线时长、单轨重叠、配音与字幕文本/时序一致、包内路径等。它**不是完整 JSON Schema 验证器**，不检查实际画面语义、文件编解码、TTS 质量或剪映导入能力。

--self-test 还会构造五个错误副本，确认过期引用、越界路径、越界源时间、字幕不一致和虚假导出成功声明被拒绝，不会改写样例文件。

占位媒体与证据边界

- 顶层和每份文档的 fixtures_only 均为 true；media/... 文件均为占位路径，仓库没有附带这些素材。
- 文件摘要使用 fixture: 前缀，不能当作真实内容哈希。
- 配音时长是为了说明对接关系而构造的样例数据，不是一次真实 TTS 测量记录。
- ExportManifest.status 是 not_exported，target_app.version 是 UNVERIFIED，没有宣称导出或导入成功。

A 或 E 接入真实媒体后，应使用实际文件和哈希替换占位数据；F 只有完成目标版本的真实导入验收，才能将导出状态写成 verified_import。生产数据验证应拒绝 fixtures_only: true。

每位同事如何使用

同事	开发时使用	首轮输出
A	清单中的六个媒体槽位；自备对应合法素材	真实 AssetManifest、关键帧与 transcript
B	AssetManifest 和 RetrievalRequest	CandidateSet；保留来源及空结果
C	Brief 和 CandidateSet	StoryPlan；事件证据与空镜职责可追溯
D	StoryPlan 和 VoicePackage	EditTimeline；负责全局时间和轨道安排
E	StoryPlan.narration_cues	逐句 WAV、实测时长、局部字幕及 needs_retime 状态
F	EditTimeline、两个媒体清单	实际预览、工程包和真实导入结果

不要把样例中的镜头选择、固定时长或声音指标直接当作业务规则。联调时可以换素材、故事和节奏，但必须保留协议所表达的来源、时序与版本关系。